



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Departamento de Sistemas Informáticos y Computación
Universidad Politécnica de Valencia

Transferencia de modelos MEG de contexto largo a EEG para clasificación de palabras en lectura natural

TRABAJO DE FIN DE MÁSTER

Máster Universitario en Inteligencia Artificial,
Reconocimiento de Formas e Imagen Digital

Autor: Ricardo Díaz Peris

Tutores: Vicent Juan Botti Navarro, Alfons Juan Císcar

Curso 2025-2026

Resum

La decodificación de palabras a partir de señales cerebrales no invasivas presenta importantes dificultades debidas al bajo nivel de señal útil, la variabilidad entre sujetos y las diferencias entre modalidades como MEG y EEG. En este trabajo se adapta el modelo MEG-XL, diseñado originalmente para el aprendizaje de representaciones de contexto largo en MEG, a un escenario de EEG durante lectura natural. La adaptación se centra en construir un pipeline reproducible para evaluar si las representaciones aprendidas en MEG pueden transferirse a EEG en tareas de clasificación de palabras. Para ello, se integra la arquitectura de MEG-XL con un nuevo adaptador diferentes datasets de EEG, que transforma los registros de este tipo de sensores y las anotaciones de lectura en segmentos alineados a palabras. El pipeline incorpora re-muestreo, normalización, extracción de ventanas temporales por palabra, máscaras de sensores y codificación explícita del tipo de sensor EEG. A partir de estos segmentos, el modelo obtiene representaciones neuronales contextualizadas mediante un Transformer con atención criss-cross y las compara con embeddings lingüísticos generados por T5 mediante una pérdida contrastiva. El objetivo principal es analizar la viabilidad técnica y experimental de trasladar modelos de contexto largo entrenados en MEG a datos EEG para comenzar a investigar una solución cerrada de brain-to-text que incluya EEG. Este enfoque permite estudiar las barreras prácticas de la transferencia entre modalidades, identificar los puntos críticos del preprocesamiento y sentar una base para futuros modelos multimodales M/EEG aplicados a decodificación de lenguaje natural.

Paraules clau: Descodificació neuronal; EEG; MEG; aprenentatge per transferència; lectura natural; classificació de paraules; models de context llarg; brain-to-text

Resumen

La descodificació de paraules a partir de senyals cerebrals no invasives presenta importants dificultats degudes al baix nivell de senyal útil, la variabilitat entre subjectes i les diferències entre modalitats com MEG i EEG. En este treball s'adapta el model MEG-XL, dissenyat originalment per a l'aprenentatge de representacions de context llarg en MEG, a un escenari d'EEG durant lectura natural. L'adaptació se centra a construir un pipeline reproduïble per a avaluar si les representacions apreses en MEG poden transferir-se a EEG en tasques de classificació de paraules. Per això, s'integra l'arquitectura de MEG-XL amb un nou adaptador per a diferents conjunts de dades d'EEG, que transforma els registres d'aquest tipus de sensors i les anotacions de lectura en segments alineats amb paraules. El pipeline incorpora remostratge, normalització, extracció de finestres temporals per paraula, màscares de sensors i codificació explícita del tipus de sensor EEG. A partir d'aquests segments, el model obté representacions neuronals contextualitzades mitjançant un Transformer amb atenció criss-cross i les compara amb embeddings lingüístics generats per T5 mitjançant una pèrdua contrastiva. L'objectiu principal és analitzar la viabilitat tècnica i experimental de traslladar models de context llarg entrenats en MEG a dades EEG per a començar a investigar una solució tancada de brain-to-text que incloga EEG. Este enfocament permet estudiar les barreres pràctiques de la transferència entre modalitats, identificar els punts crítics del preprocesament i assentar una base per a futurs models multimodals M/EEG aplicats a la descodificació de llenguatge natural.

Palabras clave: Decodificación neuronal; EEG; MEG; aprendizaje por transferencia; lectura natural; clasificación de palabras; modelos de contexto largo; brain-to-text

Abstract

Decoding words from non-invasive brain signals presents significant challenges due to the low level of useful signal, inter-subject variability, and differences between modalities such as MEG and EEG. In this work, the MEG-XL model—originally designed for learning long-range context representations in MEG—is adapted to an EEG setting during natural reading. The adaptation focuses on building a reproducible pipeline to evaluate whether representations learned in MEG can be transferred to EEG in word classification tasks. To this end, the MEG-XL architecture is integrated with a new adapter for various EEG datasets, which transforms EEG recordings and reading annotations into word-aligned segments. The pipeline incorporates resampling, normalization, word-based temporal window extraction, sensor masking, and explicit encoding of the EEG sensor type. From these segments, the model obtains contextualized neural representations using a Transformer with cross-attention and compares them with linguistic embeddings generated by T5 via a contrastive loss. The main objective is to analyze the technical and experimental feasibility of transferring long-context models trained on MEG data to EEG data in order to begin investigating an end-to-end brain-to-text solution that incorporates EEG. This approach allows us to study the practical barriers to cross-modal transfer, identify critical points in preprocessing, and lay the groundwork for future multimodal M/EEG models applied to natural language decoding.

Key words: Neural decoding; EEG; MEG; transfer learning; natural reading; word classification; long-context models; brain-to-text

Índice general

Índice general	V
Índice de figuras	VII
Índice de tablas	VIII
1 Introducción	1
1.1 Motivación	1
1.2 Objetivos	1
1.3 Estructura de la memoria	1
2 Marco teórico	3
2.1 Interfaces cerebro-computador	3
2.1.1 Decodificación cerebral del lenguaje	4
2.1.2 Métodos invasivos y no invasivos	5
2.2 Aprendizaje profundo	6
2.2.1 Redes neuronales y Transformers	6
2.2.2 Aprendizaje autosupervisado y transferencia de aprendizaje	7
2.3 Electroencefalografía y magnetoencefalografía	8
2.3.1 Electroencefalografía	8
2.3.2 Magnetoencefalografía	10
2.3.3 Comparación entre EEG y MEG	12
2.4 Procesamiento de señales cerebrales	13
2.4.1 Actividad oscilatoria y bandas de frecuencia	13
2.4.2 Preprocesamiento de EEG y MEG	14
2.4.3 Representación temporal y espacial de las señales	16
2.4.4 Aprendizaje profundo aplicado a EEG y MEG	17
2.5 Decodificación contextual de palabras	19
2.5.1 Representaciones lingüísticas	19
2.5.2 Aprendizaje contrastivo	20
2.5.3 Evaluación de la clasificación de palabras	21
2.6 Estado del arte	23
2.6.1 Decodificación no invasiva del lenguaje	23
2.6.2 Modelos preentrenados de señales cerebrales	26
2.6.3 Limitaciones de los trabajos existentes	30
3 Datasets utilizados	33
3.1 Selección de conjuntos de entrenamiento	34
3.2 Datasets de entrenamiento	34
3.2.1 Datasets de lectura	34
3.2.2 Datasets de escucha	35
3.3 Dataset de fine-tuning	37
3.3.1 OpenNeuro ds004408	37
3.4 Tabla resumen	38
4 Adaptación de MEG-XL a “EEG-XL”	39
4.1 Descripción general de la propuesta	39

4.2	Preprocesamiento del EEG	40
4.2.1	Preprocesado de la señal	40
4.2.2	Alineamiento con las palabras	41
4.3	Adaptación de la arquitectura MEG-XL	41
4.3.1	Componentes conservados	41
4.3.2	Cambios para trabajar con canales EEG	42
4.3.3	Tokenización de la señal	43
4.3.4	Modelado temporal y espacial	43
4.4	Entrenamiento del modelo	44
4.4.1	Preentrenamiento autosupervisado	44
4.4.2	Clasificación contextual de palabras	44
5	Evaluación experimental	47
5.1	Configuración de los experimentos	47
5.1.1	Particiones de los datos	47
5.1.2	Hiperparámetros y métricas	47
5.2	Entrenamiento desde cero y transferencia desde MEG-XL	47
5.2.1	Inicialización desde cero y desde MEG-XL	47
5.3	Comparación de tokenizadores	47
5.4	Comparación de tareas	47
5.4.1	Lectura	47
5.4.2	Escucha	47
5.4.3	Lectura y escucha combinadas	47
5.5	Discusión de los resultados	47
5.5.1	Principales conclusiones experimentales	47
5.5.2	Limitaciones	47
6	Conclusiones y trabajo futuro	49
6.1	Conclusiones	49
6.2	Cumplimiento de los objetivos	49
6.3	Líneas de trabajo futuro	49
	Bibliografía	51
	Apéndices	
A	Configuració del sistema	55
A.1	Fase d'inicialització	55
A.2	Identificació de dispositius	55
B	??? ???????????? ????	57

Índice de figuras

2.1	Etapas generales de una interfaz cerebro-computador. La salida del decodificador puede utilizarse directamente o cerrar el bucle mediante realimentación al usuario.	3
2.2	Principales paradigmas experimentales utilizados en decodificación cerebral del lenguaje. Cada paradigma ofrece un compromiso distinto entre naturalidad, facilidad de alineamiento y presencia de artefactos.	5
2.3	Ejemplos de adquisición invasiva y no invasiva. A la izquierda, un registro ECoG ilustra la proximidad de los electrodos a la corteza y el coste clínico asociado. A la derecha, la fMRI muestra una alternativa no invasiva con buena resolución espacial, pero menos adecuada para seguir la dinámica rápida del lenguaje.	6
2.4	Esquema conceptual de la observación de una fuente neuronal mediante EEG y MEG. Aunque ambas modalidades reflejan actividad relacionada, difieren en la magnitud física medida, la proyección sobre los sensores y las fuentes de variabilidad.	8
2.5	Ejemplo de gorro EEG con electrodos distribuidos sobre el cuero cabelludo. Su menor coste y portabilidad facilitan la adquisición de datos en comparación con MEG, aunque la calidad del registro depende del montaje, la referencia y el contacto de los electrodos.	9
2.6	Ejemplo de adquisición mediante MEG. El volumen del sistema, la posición fija del participante y la necesidad de instalaciones específicas ayudan a explicar por qué estos registros son costosos, poco portátiles y difíciles de reproducir entre laboratorios.	11
2.7	Flujo habitual de preparación de registros EEG y MEG para aprendizaje automático. El orden exacto puede variar, pero el filtrado antialiasing debe preceder al remuestreo y las particiones deben impedir fugas entre datos relacionados.	13
2.8	Esquema de clasificación contextual de palabras. Cada evento lingüístico define una ventana cerebral; las representaciones locales se contextualizan y se proyectan al espacio de un modelo de lenguaje para recuperar las palabras más próximas.	20
2.9	Resumen del preentrenamiento y del ajuste fino de MEG-XL. El modelo aprende primero a reconstruir tokens cerebrales en contextos largos y posteriormente reutiliza esas representaciones en una tarea contrastiva de clasificación contextual de palabras. Adaptado conceptualmente de Jayalath y Parker Jones.	29
2.10	Evolución simplificada de los trabajos más próximos a la decodificación no invasiva de lenguaje considerada en esta memoria. La progresión combina vocabularios mayores, contexto más largo, más datos por participante y modelos lingüísticos externos.	30

Índice de tablas

2.1	Comparación general entre EEG y MEG.	12
2.2	Principales bandas de frecuencia utilizadas en el análisis de señales EEG y MEG. Los límites y las asociaciones funcionales son aproximados.	14
3.1	Conjuntos de datos utilizados para el preentrenamiento y la evaluación de MEG-XL.	34
3.2	Resumen de los conjuntos de datos utilizados y su función dentro del proceso experimental. En ds007808, las horas de <i>listeningcovert</i> corresponden a grabaciones completas utilizadas como contexto y no a 167 horas de objetivos exclusivamente auditivos.	38
4.1	Resumen de la arquitectura y número de parámetros del modelo EEG. . .	43

CAPÍTULO 1

Introducción

????? ?????????????? ?????????????? ?????????????? ?????????????? ??????????????

1.1 Motivación

Origen video intracortical ?????? ?????????????? ?????????????? ?????????????? ??????????????
?????????????????

1.2 Objetivos

????? ?????????????? ?????????????? ?????????????? ?????????????? ??????????????

1.3 Estructura de la memoria

????? ?????????????? ?????????????? ?????????????? ?????????????? ??????????????

CAPÍTULO 2

Marco teórico

2.1 Interfaces cerebro-computador

Las interfaces cerebro-computador (BCIs) son sistemas que establecen un canal de comunicación entre la actividad cerebral de una persona y un dispositivo externo [42]. Una BCI funciona de forma parecida a un ratón o una pantalla táctil, solo que intenta interpretar directamente determinados patrones de actividad neuronal y transformarlos en una salida útil. Esta salida puede ser desde mover un cursor o seleccionar una letra hasta controlar una prótesis o generar una secuencia de texto.

Durante los últimos años el interés por este tipo de sistemas ha aumentado considerablemente. Además del trabajo que se está desarrollando en universidades y centros clínicos, la aparición de iniciativas privadas de gran visibilidad, como Neuralink, ha contribuido a acercar las BCIs al debate público [27]. Sin embargo, más allá de las expectativas generadas alrededor de estas tecnologías, su desarrollo sigue planteando dificultades importantes que iremos nombrando.

De forma más o menos general, una BCI se puede dividir en varias etapas. En primer lugar, la actividad cerebral se registra mediante una modalidad de adquisición, como la electroencefalografía (EEG), magnetoencefalografía (MEG), resonancia magnética funcional (fMRI) o electrocorticografía (ECoG), todas descritas más adelante. Después, la señal obtenida se preprocesa para reducir ruido, artefactos y diferencias de escala. Sobre estos datos se extrae una representación que conserve la información relevante para la tarea. Finalmente, un modelo de decodificación transforma dicha representación en una predicción y, en los sistemas en línea, esta predicción se utiliza para actuar sobre un dispositivo o proporcionar *feedback* al usuario.



Figura 2.1: Etapas generales de una interfaz cerebro-computador. La salida del decodificador puede utilizarse directamente o cerrar el bucle mediante realimentación al usuario.

No todas las BCIs persiguen el mismo objetivo, algunas se basan en reconocer actividad generada voluntariamente por el usuario, como la imaginación motora o el habla imaginada. También existen sistemas pasivos que no buscan ejecutar una orden, sino estimar estados como la carga cognitiva, la atención o la fatiga. Dentro de esta variedad de aplicaciones, la decodificación cerebral del lenguaje es una de las líneas de investigación más ambiciosas, ya que pretende recuperar información lingüística directamente a partir de la actividad neuronal.

2.1.1. Decodificación cerebral del lenguaje

Se llama decodificación cerebral del lenguaje a la tarea de producir información relacionada con el habla o la lectura a partir de señales cerebrales. Dependiendo del experimento, esta tarea puede centrarse en fonemas, sílabas, palabras, frases completas o propiedades semánticas de los datos que proporciona el participante. Cuando el objetivo final es reconstruir texto de forma continua, se suele emplear el término *brain-to-text*. No obstante, antes de alcanzar una transcripción completa, gran parte de la investigación se centra en tareas intermedias más controladas, como la detección de presencia de habla, la clasificación de fonemas o la identificación de palabras dentro de un vocabulario limitado [30, 21].

Hay diferentes situaciones o tareas en las que el lenguaje puede estar presente. En el *habla producida* o *overt speech*, la persona pronuncia en el experimento una palabra o una frase. Así se puede comprobar fácilmente el contenido generado, pero introduce las señales neurológicas relacionadas con el movimiento muscular de la boca, la lengua y la mandíbula. En el *habla imaginada*, llamada *covert speech*, *inner speech* o habla interna, lo que hace la persona es imaginar que pronuncia el contenido sin mover voluntariamente ningún músculo ni generar sonido. Esta segunda tarea resulta especialmente interesante para personas que no pueden hablar, que son las personas objetivo de este tipo de experimentos y sistemas, aunque también es más difícil de registrar y verificar [31, 2].

Una tercera posibilidad y en la que se desarrolla este trabajo es estudiar la percepción del habla. En este tipo de experimentos, el participante escucha palabras, frases o narraciones mientras se registra su actividad cerebral. Al existir un estímulo acústico conocido, es posible alinear con precisión los eventos lingüísticos con la señal neuronal. Esta característica ha permitido crear conjuntos de datos de gran tamaño basados en audiolibros y habla continua, como LibriBrain, en el que un participante escucha más de 50h de narraciones en inglés mientras se registra su actividad cerebral usando MEG [30]. Aunque escuchar habla no equivalga a producirla o imaginarla, resulta más adecuada que los anteriores para estudiar representaciones lingüísticas y desarrollar modelos de decodificación no invasiva a gran escala.

Por último, dentro de la percepción del habla existe la opción de utilizar la lectura en lugar de la escucha. En este caso, la actividad cerebral que se registra mientras el participante procesa palabras presentadas de forma aislada o dentro de frases. La lectura natural introduce una dificultad adicional: cada persona fija la mirada sobre las palabras durante intervalos diferentes y puede omitir o volver a leer fragmentos del texto. Por este motivo, algunos conjuntos de datos combinan EEG y seguimiento ocular. El *eye-tracking* permite localizar el inicio y la duración de cada fijación y, a partir de esta información, extraer segmentos de EEG asociados a palabras concretas. ZuCo es uno de los ejemplos más conocidos de este tipo de adquisición, ya que proporciona EEG de alta densidad y seguimiento ocular simultáneo durante la lectura natural de frases [19]. Otros datasets, en cambio, presentan palabras de forma aislada y controlan la duración de la presentación, lo que permite alinear la señal con mayor precisión [31, 2].

La señal relacionada con una palabra tiene más profundidad que simplemente el instante exacto en el que esta aparece. El procesamiento lingüístico tiene dependencias a diferentes escalas temporales. Los fonemas se agrupan en sílabas, las sílabas en palabras y las palabras adquieren diferentes significados dentro de frases y discursos. Además, la respuesta cerebral a una palabra puede depender de las palabras anteriores, de las expectativas del lector u oyente y del estado general del participante. Por ello, los enfoques recientes no solo analizan ventanas aisladas, sino secuencias de segmentos neuronales consecutivos. Esta incorporación de contexto permite al modelo utilizar relaciones entre

palabras y patrones cerebrales que no son visibles cuando cada segmento se procesa de manera independiente [9, 23].




Figura 2.2: Principales paradigmas experimentales utilizados en decodificación cerebral del lenguaje. Cada paradigma ofrece un compromiso distinto entre naturalidad, facilidad de alineamiento y presencia de artefactos.

2.1.2. Métodos invasivos y no invasivos

Las técnicas utilizadas para registrar actividad cerebral se pueden dividir, de forma muy general, en métodos invasivos y no invasivos. Los métodos invasivos requieren una intervención quirúrgica para situar los sensores o sobre la superficie del cerebro o dentro del tejido cerebral. Entre ellos se encuentran la ECoG y los conjuntos de microelectrodos intracorticales.

La principal ventaja de los métodos invasivos es la calidad de la señal. Al encontrarse tan cerca de donde se genera la actividad neuronal, los electrodos registran señales con mayor amplitud, mejor resolución espacial y menos atenuación que los sensores externos. Esta proximidad ha permitido obtener resultados muy destacados en decodificación tanto motora como del habla. En particular, algunos sistemas invasivos han conseguido reconstruir texto o sintetizar voz en personas con parálisis a partir de actividad cortical relacionada con los intentos del habla [21]. Sin embargo, estas prestaciones se obtienen a cambio de riesgos quirúrgicos, posibles infecciones, degradación de los electrodos y una cobertura limitada a las regiones implantadas. Por estos motivos, su utilización suele restringirse a casos clínicos muy concretos y entornos de investigación controlados.

Los métodos no invasivos, en cambio, registran la actividad cerebral sin necesidad de cirugía. Dentro de este grupo se encuentran sobre todo EEG, MEG y resonancia magnética (fMRI). Estas técnicas reducen considerablemente los riesgos para el participante y permiten realizar estudios replicables con mayor facilidad. Su principal limitación es la calidad de la señal, ya que debe atravesar diferentes tejidos o medirse a cierta distancia de su origen, lo que disminuye su resolución y añade mucho ruido.

Dentro de estos métodos, EEG y MEG destacan por su elevada resolución temporal. Ambas modalidades permiten seguir cambios cerebrales del orden de milisegundos, esta propiedad es muy importante para estudiar procesos tan rápidos como es la percepción de fonemas o palabras. La resonancia magnética funcional ofrece una mejor resolución




Figura 2.3: Ejemplos de adquisición invasiva y no invasiva. A la izquierda, un registro ECoG ilustra la proximidad de los electrodos a la corteza y el coste clínico asociado. A la derecha, la fMRI muestra una alternativa no invasiva con buena resolución espacial, pero menos adecuada para seguir la dinámica rápida del lenguaje.

espacial, pero su respuesta es mucho más lenta y dificulta la separación temporal de palabras consecutivas. EEG y MEG constituyen, por tanto, un compromiso especialmente interesante entre seguridad y capacidad para representar la dinámica temporal del lenguaje.

Hay que tener en cuenta estos factores a la hora de entrenar diferentes modelos. Los sistemas invasivos disponen de señales más localizadas y, según el estudio, de muchas horas registradas para un mismo paciente. En cambio, los modelos no invasivos deben aprender a trabajar con señales más débiles, sensores distribuidos por toda la cabeza y una variabilidad elevada.

2.2 Aprendizaje profundo

El aprendizaje profundo permite aprender representaciones directamente a partir de datos de alta dimensión. Comparado con los métodos clásicos, que dependen en mayor medida de características diseñadas manualmente, una red neuronal puede optimizar conjuntamente la extracción de patrones y la tarea final. Esta propiedad ha hecho que las redes profundas se utilicen en dominios muy diferentes, como visión por computador, procesamiento del lenguaje, audio o señales temporales.

Sin embargo, utilizar modelos más grandes no siempre significa obtener un mejor resultado. Una arquitectura con demasiados parámetros puede memorizar particularidades del conjunto de entrenamiento y generalizar mal a datos nuevos. Por este motivo, el diseño del modelo debe acompañarse de regularización, particiones rigurosas, múltiples semillas y comparaciones frente a modelos sencillos.

2.2.1. Redes neuronales y Transformers

Una red neuronal transforma una entrada mediante una sucesión de capas parametrizadas. Cada capa combina los valores de la anterior y aplica una función no lineal. Durante el entrenamiento, los parámetros se ajustan para reducir una función de pérdida (*loss*). En clasificación, esta *loss* mide la diferencia entre las predicciones del modelo y las etiquetas reales. En aprendizaje de representaciones, puede medir la capacidad para reconstruir una entrada o acercar ejemplos relacionados.

Las redes totalmente conectadas pueden utilizarse sobre vectores de características, pero no aprovechan de forma explícita la estructura local de una señal o una imagen. Las

redes convolucionales, conocidas como CNNs, aplican filtros locales que se desplazan por la entrada. En una señal temporal, una convolución puede detectar patrones cortos que aparecen en distintos momentos, mientras que las convoluciones dilatadas aumentan el campo receptivo sin necesitar un número excesivo de capas [11, 9].

Las CNNs también pueden operar sobre representaciones tiempo-frecuencia o mapas espaciales. Su principal limitación es que las dependencias muy largas solo se modelan después de acumular numerosas capas o aumentar considerablemente el campo receptivo. Las redes recurrentes, por su parte, procesan las muestras de forma secuencial y mantienen un estado interno. Arquitecturas como LSTM y GRU fueron diseñadas para conservar información a largo plazo mejor que las redes recurrentes simples, aunque su entrenamiento secuencial dificulta el paralelismo y puede resultar costoso con secuencias largas.

Los Transformers sustituyen la recurrencia por mecanismos de atención [38]. Para una secuencia de vectores, cada elemento se transforma en una consulta, una clave y un valor. La atención calcula la similitud entre consultas y claves y utiliza estos pesos para combinar los valores:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right) \mathbf{V}.$$

Gracias a este mecanismo, una posición puede acceder directamente a cualquier otra posición de la secuencia. Esto resulta útil cuando la predicción de un elemento depende de información situada en otro punto del contexto.

El modelo necesita también información sobre el orden. Los *embeddings* posicionales, ya sean aprendidos, sinusoidales o rotatorios, indican la posición temporal de cada elemento. Sin ellos, el mecanismo de atención trataría la secuencia como un conjunto sin orden. La atención completa tiene, no obstante, un coste cuadrático respecto al número de elementos, por lo que las secuencias largas suelen requerir variantes eficientes, atención local o factorizaciones de la atención.

2.2.2. Aprendizaje autosupervisado y transferencia de aprendizaje

El aprendizaje supervisado necesita pares de entrada y etiqueta. Cuando las etiquetas son escasas o costosas, el aprendizaje autosupervisado intenta aprovechar datos sin anotaciones manuales. La propia entrada proporciona el objetivo de entrenamiento: por ejemplo, se puede ocultar una parte de ella y pedir al modelo que la reconstruya a partir del contexto. Esta estrategia se utiliza en modelos de lenguaje enmascarado, audio y visión [12, 5].

Después del preentrenamiento se realiza una adaptación o *fine-tuning*. El modelo recibe ejemplos de la tarea final y sus parámetros se ajustan para resolverla. Si las representaciones aprendidas son útiles, el modelo necesita menos datos etiquetados que uno inicializado aleatoriamente. Otra forma de evaluación es el *linear probing*, donde el modelo preentrenado se mantiene congelado y solo se entrena una capa lineal. Este procedimiento mide la calidad de las representaciones sin permitir que toda la red se adapte a la nueva tarea.

La transferencia de aprendizaje (*transfer learning*) puede realizarse entre tareas, conjuntos de datos o dominios. Para que sea efectiva, es necesario distinguir entre componentes generales y específicos del dominio. Las primeras capas pueden aprender patrones básicos reutilizables, mientras que otras partes del modelo pueden depender fuertemente de la distribución de entrenamiento. Asimismo, debe considerarse la transferencia negativa: un modelo preentrenado puede rendir peor si las representaciones aprendidas

no son adecuadas para el nuevo dominio. Por ello, la transferencia debe compararse con un modelo entrenado desde cero utilizando la misma arquitectura y los mismos datos.

2.3 Electroencefalografía y magnetoencefalografía

Las corrientes postsinápticas, provenientes de poblaciones de neuronas, producen tanto potenciales eléctricos (EEG) como campos magnéticos (MEG). EEG registra las diferencias de potencial que llegan al cuero cabelludo, mientras que MEG mide los campos magnéticos producidos alrededor de la cabeza. Pese a que ambas modalidades ofrecen una resolución temporal elevada, sus propiedades físicas, su distribución espacial y sus sistemas de adquisición son diferentes.

Esta diferencia es lo suficientemente importante como para dedicarle un par de subsecciones en este trabajo, sobre todo al tratar de realizar una transferencia de un tipo de método al otro. Un modelo no recibe directamente la actividad de las fuentes cerebrales, sino una mezcla de dichas fuentes observada a través de una disposición concreta de sensores. Por tanto, cambiar de MEG a EEG no consiste únicamente en modificar el número de canales. También cambian la amplitud, la geometría, el tipo de ruido, la referencia y la relación entre cada sensor y las fuentes neuronales.




Figura 2.4: Esquema conceptual de la observación de una fuente neuronal mediante EEG y MEG. Aunque ambas modalidades reflejan actividad relacionada, difieren en la magnitud física medida, la proyección sobre los sensores y las fuentes de variabilidad.

2.3.1. Electroencefalografía

La EEG registra diferencias de potencial eléctrico utilizando electrodos colocados sobre el cuero cabelludo. Estas diferencias se producen por la actividad sincronizada de grandes poblaciones de neuronas corticales. La amplitud registrada suele ser muy pequeña, en el orden de los microvoltios ($1 \mu V = 10^{-6} V$), por lo que el sistema de adquisición necesita amplificar señales muy pequeñas y mantener un buen contacto entre los electrodos y la piel.

La colocación de estos electrodos suele seguir sistemas estandarizados, como el sistema internacional 10–20 y sus extensiones 10–10 o 10–5 [20, 29]. Estos sistemas asignan diferentes nombres a las posiciones en función de la región aproximada de la cabeza: frontal, central, temporal, parietal y occipital. En montajes de alta densidad se pueden utilizar 64, 128 o incluso más canales. Un mayor número de electrodos proporciona una observación espacial más detallada, aunque también incrementa el tiempo de preparación, la posibilidad de canales defectuosos y el coste computacional.



Figura 2.5: Ejemplo de gorro EEG con electrodos distribuidos sobre el cuero cabelludo. Su menor coste y portabilidad facilitan la adquisición de datos en comparación con MEG, aunque la calidad del registro depende del montaje, la referencia y el contacto de los electrodos.

Asimismo, hay que tener en cuenta que EEG es una medida relativa. Cada canal de EEG representa la diferencia entre un electrodo y una referencia o una combinación de ellas. La elección de esta referencia afecta a la forma de la señal y debe tenerse en cuenta al comparar conjuntos de datos. Entre las opciones habituales se encuentran la referencia a un electrodo concreto, la referencia promedio de todos los canales o las configuraciones bipolares. En conjuntos de datos que están recogidos con diferentes sistemas, una estrategia de referencia homogénea puede reducir parte de las diferencias, pero no elimina por completo la variabilidad entre los montajes.

Como se ha indicado antes, una de las principales ventajas de EEG es su resolución temporal. Es capaz de registrar frecuencias de cientos o miles de muestras por segundo, lo que permite estudiar respuestas rápidas asociadas a estímulos visuales, auditivos o lingüísticos. A su vez es una tecnología –relativamente– económica, portátil y compatible con experimentos más fieles al uso que tendrían los modelos. Estas características explican su uso frecuente en BCI y en estudios de lectura, donde puede combinarse con seguimiento ocular para obtener segmentos asociados a cada fijación [19]

Su principal limitación es la resolución espacial. Los potenciales eléctricos se propagan a través del cerebro, el líquido cefalorraquídeo, el cráneo y el cuero cabelludo. La conductividad de estos tejidos produce un fenómeno de difusión conocido como conducción de volumen, por el cual una misma fuente puede afectar a numerosos electrodos. Como consecuencia, la actividad que se observa en un canal no puede asociarse directamente a una única región cerebral.

Por otro lado, las señales EEG pueden contaminarse con actividad que no procede directamente del cerebro (estas contaminaciones se llaman artefactos). Los parpadeos y movimientos oculares generan señales de gran amplitud en los electrodos frontales. La tensión muscular, el movimiento de la mandíbula, el latido cardíaco, el desplazamiento de los cables y el contacto deficiente de los electrodos pueden ocultar la actividad neuronal. En tareas de habla producida, los artefactos musculares son especialmente relevantes. En lectura natural, los movimientos oculares forman parte de la propia tarea, de modo que su tratamiento debe realizarse con cuidado para no eliminar información relacionada indirectamente con el procesamiento lingüístico.

2.3.2. Magnetoencefalografía

Por su parte, la magnetoencefalografía (MEG) registra los campos magnéticos generados por la actividad neuronal. La magnitud física medida es la densidad de flujo magnético, cuya unidad en el Sistema Internacional es el tesla (T); un tesla equivale a un weber por metro cuadrado. Puesto que esta unidad resulta demasiado grande para describir la actividad cerebral, las señales MEG suelen expresarse en femtoteslas, donde $1 \text{ fT} = 10^{-15} \text{ T}$. Los campos producidos por la actividad neuronal suelen encontrarse en el rango de decenas o centenares de femtoteslas, mientras que el campo magnético terrestre es del orden de decenas de microteslas. Por tanto, las señales cerebrales pueden ser entre ocho y diez órdenes de magnitud menores que el campo ambiental [18]. Esta diferencia permite interpretar la elevada sensibilidad requerida y explica por qué las mediciones deben realizarse mediante sensores especializados dentro de salas magnéticamente apantalladas.

Los sistemas MEG tradicionales emplean dispositivos superconductores de interferencia cuántica, conocidos como SQUID por sus siglas en inglés (*Superconducting Quantum Interference Devices*). Estos dispositivos permiten detectar variaciones extremadamente pequeñas del flujo magnético, pero deben funcionar en régimen superconductor a temperaturas criogénicas, por lo que se alojan en un criostato que mantiene los sensores separados físicamente de la cabeza del participante [18]. Asimismo, se están desarrollando sistemas basados en magnetómetros de bombeo óptico u OPM (*Optically Pumped Magnetometers*), que no requieren superconductividad ni un criostato. Esto permite situar los sensores más cerca del cuero cabelludo, adaptar su distribución a la forma y el tamaño de cada cabeza y construir dispositivos más flexibles y tolerantes al movimiento [6].

Los sistemas MEG suelen incluir dos tipos de sensores: magnetómetros y gradiómetros. Los magnetómetros miden directamente una componente de la densidad de flujo magnético en la posición del sensor. Los gradiómetros, en cambio, registran la diferencia entre las medidas obtenidas en dos bobinas próximas, proporcionando una aproximación al gradiente espacial del campo. Como las fuentes ambientales lejanas tienden a producir campos similares en ambas bobinas, esta diferencia permite atenuar parte de las interferencias externas. Un equipo MEG de cuerpo completo puede contener más de trescientos canales distribuidos alrededor de la cabeza. Por ejemplo, LibriBrain fue registrado con un sistema MEGIN Triux Neo de 306 canales [30].

A diferencia de los potenciales eléctricos, los campos magnéticos atraviesan el cráneo y el cuero cabelludo con una distorsión menor, debido a que la permeabilidad magnética de estos tejidos es muy similar a la del espacio que los rodea. Esto proporciona a MEG una resolución espacial superior a la de EEG en muchas condiciones, manteniendo una resolución temporal del orden de milisegundos [18, 16]. Estas propiedades han convertido MEG en una modalidad especialmente utilizada para estudiar la percepción auditiva, el lenguaje y el habla continua [10].

MEG presenta, no obstante, limitaciones importantes. El equipamiento tiene un coste mucho más elevado que el de EEG, requiere instalaciones específicas y, en los sistemas SQUID convencionales, no es fácilmente transportable. El participante debe permanecer relativamente quieto, ya que el movimiento de la cabeza modifica la relación espacial entre las fuentes cerebrales y los sensores. Además, los datos ocupan un volumen considerable y su procesamiento suele incluir pasos específicos, como la corrección del movimiento de la cabeza, la detección de canales defectuosos y la reducción de señales procedentes del exterior del casco [16].



Figura 2.6: Ejemplo de adquisición mediante MEG. El volumen del sistema, la posición fija del participante y la necesidad de instalaciones específicas ayudan a explicar por qué estos registros son costosos, poco portátiles y difíciles de reproducir entre laboratorios.

Una de las técnicas empleadas con este último propósito es *Signal Space Separation* (SSS). Este método representa las mediciones mediante bases espaciales diferentes para los campos generados dentro del volumen que contiene la cabeza y para los campos originados fuera de este. De esta forma, pueden descartarse los componentes asociados principalmente a interferencias externas. SSS, junto con sus extensiones temporales y los pro-

cedimientos de compensación del movimiento, se implementa habitualmente mediante el denominado filtrado de Maxwell [37].

Otra propiedad relevante es que los sistemas MEG no comparten necesariamente la misma disposición de sensores. Distintos fabricantes utilizan cantidades, tipos y geometrías diferentes. Incluso dentro de un mismo sistema, la posición y orientación de la cabeza respecto al casco pueden cambiar entre participantes o sesiones. Para combinar datos de varios conjuntos, los modelos deben representar de algún modo la localización, la orientación y el tipo de cada sensor, o transformar previamente las señales a un espacio común.

MEG ha permitido desarrollar algunos de los conjuntos de datos más relevantes para la decodificación no invasiva del habla. La mayor calidad espacial de la señal, unida a adquisiciones prolongadas, ha facilitado tareas de detección de habla, clasificación de fonemas y clasificación contextual de palabras. Estos resultados hacen que los modelos preentrenados con MEG constituyan una base interesante para estudiar su transferencia a EEG, aunque las diferencias físicas, espaciales e instrumentales entre ambas modalidades impiden asumir que dicha transferencia será directa.

2.3.3. Comparación entre EEG y MEG

EEG y MEG comparten su carácter no invasivo y su elevada resolución temporal, pero presentan diferencias importantes en la forma en que observan la actividad cerebral. La Tabla 2.1 resume las propiedades más relevantes para este trabajo.

Tabla 2.1: Comparación general entre EEG y MEG.

Propiedad	EEG	MEG
Magnitud	Potencial eléctrico	Campo magnético
Temporal	Milisegundos	Milisegundos
Espacial	Menor; conducción de volumen; referencia	Mayor; menor distorsión tisular
Fuentes	Radiales; tangenciales	Principalmente tangenciales
Artefactos	Oculares; musculares; referencia; contacto	Movimiento; interferencias; musculares
Coste	Bajo; portátil	Alto; sala apantallada
Preparación	Electrodos; impedancias; referencia	Casco; sensores; posición; movimiento
Variabilidad	Montaje; referencia; amplificador; muestreo	Geometría; tipo de sensor; posición de cabeza

Desde el punto de vista del aprendizaje automático, ambas modalidades suelen representarse inicialmente como una matriz de canales por tiempo. Sin embargo, esta similitud de formato puede dar lugar a errores conceptuales. Los canales de EEG y MEG no son intercambiables, y una misma fuente cortical se proyecta de forma diferente en cada modalidad. Además, EEG suele tener menos canales y una relación señal-ruido inferior, mientras que MEG proporciona una estructura espacial más rica.

Estas diferencias generan un problema de cambio de dominio. Un modelo entrenado con MEG puede haber aprendido patrones que dependen de la geometría de sus sensores, de la amplitud de la señal o del tipo de ruido presente en el escáner. Al aplicarlo sobre EEG, estas relaciones dejan de cumplirse. Por ello, la transferencia requiere adaptar la entrada, normalizar la señal, representar la posición de los electrodos y, en muchos casos, reajustar parte o la totalidad del modelo.

Aun así, EEG y MEG comparten información temporal y neurofisiológica. Ambas modalidades reflejan la actividad coordinada de poblaciones neuronales y contienen respuestas relacionadas con el procesamiento de palabras. Esta base común justifica estudiar si las representaciones aprendidas mediante preentrenamiento MEG pueden aportar información útil para EEG, especialmente en escenarios con pocos datos etiquetados. El objetivo no es asumir que ambas señales son iguales, sino determinar qué partes del conocimiento aprendido son transferibles y qué componentes deben adaptarse.

2.4 Procesamiento de señales cerebrales

En esta sección y durante el resto del trabajo se empleará el término frecuencia con dos significados diferentes y cabe recalcar la diferencia. Por un lado, la frecuencia de muestreo, expresada en hercios, indica el número de valores de la señal registrados por segundo y determina su resolución temporal. Por otro, la frecuencia de las componentes de la señal describe el número de oscilaciones por segundo de la actividad registrada, como las asociadas a las distintas bandas cerebrales o a fuentes de ruido. Aunque ambas magnitudes se expresan en hercios, representan conceptos distintos: la primera describe cómo se digitaliza la señal, mientras que la segunda caracteriza su contenido espectral.

Como se ha comentado previamente, las señales EEG y MEG se registran como series temporales multicanal. Si se utilizan C sensores y se obtienen T muestras, una grabación se puede representar como una matriz

$$\mathbf{X} \in \mathbb{R}^{C \times T}.$$

Además de información temporal y espacial, esta representación contiene ruido, artefactos y diferencias entre instrumentos. Antes de entrenar un modelo es necesario decidir qué parte de la señal se conserva, cómo se normaliza y cómo se divide en muestras.

El procesamiento no debe entenderse únicamente como una limpieza previa. Cada decisión modifica la información que el modelo puede utilizar. Un filtro demasiado restrictivo puede eliminar componentes relacionadas con la tarea, mientras que una limpieza insuficiente puede hacer que el sistema aprenda artefactos. Del mismo modo, una segmentación incorrecta puede asociar una etiqueta lingüística a una ventana que no contiene la respuesta cerebral correspondiente.




Figura 2.7: Flujo habitual de preparación de registros EEG y MEG para aprendizaje automático. El orden exacto puede variar, pero el filtrado antialiasing debe preceder al remuestreo y las particiones deben impedir fugas entre datos relacionados.

2.4.1. Actividad oscilatoria y bandas de frecuencia

La actividad registrada mediante EEG y MEG suele estudiarse en el dominio de la frecuencia. La frecuencia representa el número de ciclos de una oscilación que se producen

en un segundo y se expresa en hercios. De manera aproximada, estas oscilaciones suelen agruparse en las bandas delta, theta, alfa, beta y gamma. Esta división permite resumir cambios en la actividad cerebral y estudiar su relación con diferentes estados fisiológicos y procesos cognitivos.

Tabla 2.2: Principales bandas de frecuencia utilizadas en el análisis de señales EEG y MEG. Los límites y las asociaciones funcionales son aproximados.

Banda	Intervalo aproximado	Asociaciones habituales
Delta	0.5–4 Hz	Sueño profundo y actividad cerebral lenta.
Theta	4–8 Hz	Procesos de aprendizaje, memoria y control cognitivo.
Alfa	8–13 Hz	Estados de reposo, regulación de la atención e inhibición de información no relevante.
Beta	13–30 Hz	Procesamiento cognitivo y sensoriomotor activo.
Gamma	> 30 Hz	Integración de información y diferentes procesos perceptivos y cognitivos.

Estas asociaciones deben entenderse de manera aproximada, ya que las bandas no representan componentes completamente independientes ni se corresponden de forma exclusiva con una única función cerebral. Su interpretación depende de la región registrada, de la tarea realizada y del momento analizado [8, 26, 15].

En los estudios de habla imaginada se han utilizado combinaciones muy diferentes de frecuencias, desde bandas bajas hasta intervalos gamma, sin que exista una banda universalmente óptima para todos los participantes, tareas y conjuntos de datos [31, 2]. Por este motivo, tanto los límites del filtrado como la frecuencia de muestreo deben considerarse decisiones relevantes cuando se adapta un modelo a nuevos conjuntos de EEG. Una frecuencia de muestreo reducida disminuye el coste computacional, pero limita las componentes espectrales que pueden conservarse.

2.4.2. Preprocesamiento de EEG y MEG

El primer paso suele ser comprobar la calidad de la grabación. Durante esta revisión se identifican canales planos, saturados o excesivamente ruidosos. Estos canales pueden eliminarse, interpolarse a partir de sensores vecinos o marcarse para que el modelo no los utilice. A su misma vez es importante verificar la sincronización entre la señal cerebral y los eventos del experimento, especialmente cuando las ventanas se alinean con el inicio de una palabra, un estímulo auditivo o una fijación ocular.

En EEG, el preprocesamiento puede incluir una nueva referencia de los canales. La referencia promedio es una opción común en sistemas de alta densidad, aunque su idoneidad depende de la cobertura de electrodos. Del mismo modo se revisan las impedancias y se eliminan canales periféricos muy afectados por actividad muscular. En MEG no existe una referencia eléctrica equivalente, pero son habituales la corrección del movimiento de la cabeza y los métodos que separan las fuentes internas y externas al casco. En *LibriBrain*, por ejemplo, se aplica filtrado de Maxwell, eliminación de canales defectuosos, filtros para la red eléctrica y reducción de la frecuencia de muestreo [30].

El filtrado temporal busca conservar un intervalo de frecuencias útil y reducir componentes no deseadas. Un filtro paso alto elimina las variaciones muy lentas y la deriva de la línea base. Un filtro paso bajo reduce el ruido de alta frecuencia y prepara la señal para un posible remuestreo. En EEG también se utilizan filtros *notch* en la frecuencia de la red eléctrica, que en Europa es de 50 Hz, y en algunos de sus armónicos. La elección de los límites debe estar relacionada con la tarea y con la nueva frecuencia de muestreo. Antes de reducir la frecuencia es necesario aplicar un filtrado *antialiasing* que elimine compo-

nentes superiores a la frecuencia de Nyquist. Esta frecuencia corresponde a la mitad de la frecuencia de muestreo, es decir,

$$f_{\text{Nyquist}} = \frac{f_s}{2},$$

y determina la frecuencia máxima que puede representarse correctamente en una señal digital. Las componentes situadas por encima de este límite pueden aparecer como frecuencias más bajas tras el remuestreo, dando lugar al fenómeno de *aliasing*.

El remuestreo reduce la cantidad de puntos temporales y, por tanto, el coste de almacenamiento y entrenamiento. Esta reducción es especialmente importante en modelos de contexto largo, donde el número de elementos de entrada crece con la duración, el número de canales y la frecuencia de muestreo. MEG-XL, por ejemplo, utiliza señales remuestreadas a 50 Hz para poder procesar ventanas de dos minutos y medio [23]. Sin embargo, una frecuencia menor limita las componentes espectrales disponibles. En EEG no existe una frecuencia óptima universal para la decodificación de palabras, por lo que su selección debe evaluarse experimentalmente.

La eliminación de artefactos es uno de los pasos más delicados. En EEG se emplea con frecuencia el análisis de componentes independientes, conocido como ICA, para separar fuentes con patrones espaciales y temporales distintos. Posteriormente, se identifican los componentes asociados a parpadeos, movimientos oculares, actividad cardíaca o tensión muscular. ZuCo utiliza una estrategia automática basada en ICA para eliminar componentes oculares y musculares antes de sincronizar EEG y seguimiento ocular [19].

A pesar de su utilidad, la eliminación de artefactos no está exenta de riesgos. En una tarea de lectura, la actividad ocular está relacionada con el momento en que se procesa cada palabra. Eliminar toda señal correlacionada con los ojos podría suprimir parte de la estructura temporal necesaria para la alineación. De manera similar, en habla producida, un modelo puede alcanzar una precisión elevada utilizando actividad muscular en lugar de actividad cerebral. Por ello, el tratamiento de artefactos debe ajustarse al objetivo del experimento y acompañarse de controles que permitan detectar atajos no deseados.

Después del filtrado, las señales suelen normalizarse. Una normalización global puede verse dominada por diferencias entre sesiones o por valores extremos. Por este motivo, se utilizan estrategias por canal, por grabación o por segmento. Entre ellas se encuentran la estandarización mediante media y desviación típica, la normalización robusta mediante mediana y rango intercuartílico y el recorte de valores extremos. MEG-XL divide las muestras largas en subsegmentos de tres segundos, corrige la línea base, normaliza mediante estadísticos robustos y limita los valores a un intervalo fijo [23]. Este tipo de transformación reduce las diferencias de escala sin depender excesivamente de valores anómalos.

La última etapa es la segmentación. En clasificación de palabras, cada ejemplo se obtiene normalmente a partir de una ventana alineada con un evento lingüístico. En escucha, este evento puede ser el inicio de la palabra en el audio. En lectura, puede ser el momento en que comienza una fijación sobre la palabra. La ventana puede incluir señal anterior al evento para corregir la línea base y señal posterior para capturar respuestas tardías. Cuando se procesan secuencias completas, varias ventanas consecutivas se agrupan manteniendo su orden original.

Asimismo, la división entre entrenamiento, validación y prueba forma parte del procesamiento. No es suficiente con separar ventanas aleatoriamente si segmentos cercanos pertenecen a la misma grabación o al mismo estímulo. Esto puede producir fugas de información, ya que el modelo reconoce propiedades específicas de la sesión o del contenido. Siempre que sea posible, deben mantenerse sesiones, sujetos o estímulos completos

dentro de una única partición. En conjuntos donde varios participantes reciben el mismo estímulo, todas las repeticiones de dicho estímulo deben asignarse a la misma partición.

2.4.3. Representación temporal y espacial de las señales

La forma más directa de representar EEG o MEG es utilizar la matriz original de canales por tiempo. Esta opción conserva la señal con pocas suposiciones previas y permite que los modelos aprendan sus propias características. Sin embargo, exige una arquitectura capaz de manejar secuencias largas, diferencias de escala y relaciones entre sensores.

Si ese no es el caso, una alternativa clásica consiste en extraer características temporales o estadísticas, como media, varianza, potencia, coeficientes autorregresivos o amplitud de potenciales relacionados con eventos. Estas representaciones reducen la dimensionalidad, pero dependen de decisiones manuales y pueden perder información. En habla imaginada se han utilizado además características de conectividad, patrones espaciales comunes y matrices de covarianza [31, 2].

Las representaciones tiempo-frecuencia describen cómo cambia el contenido espectral a lo largo de la señal. Para obtenerlas se emplean transformadas de Fourier de tiempo corto, bancos de filtros o transformadas wavelet. El resultado puede visualizarse como un espectrograma o escalograma [9]. Estas imágenes permiten aplicar redes convolucionales desarrolladas originalmente para visión. No obstante, convertir una señal multicanal en una imagen obliga a decidir cómo se colocan los sensores y cómo se combinan sus dimensiones. Una representación inadecuada puede mezclar canales sin respetar su posición real.

La dimensión espacial puede modelarse de varias formas. En EEG, la disposición de los electrodos sobre la cabeza se puede proyectar a un mapa bidimensional. En MEG, se dispone de la posición y orientación tridimensional de los sensores, además de su tipo. Además, pueden utilizarse matrices de covarianza o correlación para representar la relación entre canales. Otra posibilidad es reconstruir las fuentes corticales y trabajar en espacio cerebral, aunque este proceso requiere modelos anatómicos y añade una etapa de estimación.

Estas decisiones de representación condicionan después qué arquitectura puede utilizarse. Un modelo temporal necesita conservar el orden de las muestras, un modelo espacial necesita información sobre la disposición de los sensores y un modelo contextual necesita agrupar ventanas consecutivas sin mezclar ejemplos que pertenezcan a divisiones distintas.

La representación temporal depende de la longitud del contexto. Los métodos basados en palabras aisladas utilizan ventanas de unos pocos segundos y predicen cada ejemplo de forma independiente. Los modelos contextuales reciben secuencias de ventanas y pueden relacionar la respuesta de una palabra con las anteriores y posteriores.

El contexto largo no implica conservar únicamente frecuencias lentas. Un filtro paso alto puede eliminar deriva de muy baja frecuencia y, aun así, el modelo puede aprender dependencias estadísticas entre eventos separados por varios segundos o minutos. La frecuencia de la señal indica la velocidad de sus oscilaciones, mientras que el contexto determina durante cuánto tiempo puede relacionar el modelo diferentes patrones. Son conceptos distintos y ambos influyen en la información disponible.

2.4.4. Aprendizaje profundo aplicado a EEG y MEG

El aprendizaje profundo permite aprender representaciones directamente a partir de señales de alta dimensión. Comparado con los métodos clásicos, que dependen de características diseñadas manualmente, una red neuronal puede optimizar conjuntamente la extracción de patrones y la tarea final. Esta capacidad es especialmente útil en EEG y MEG, donde las relaciones relevantes pueden aparecer de forma distribuida entre canales, frecuencias y momentos temporales.

Sin embargo, utilizar modelos más grandes no siempre significa obtener un mejor resultado. Como ya se ha explicado, las señales cerebrales presentan pocos ejemplos etiquetados, una variabilidad elevada y una relación señal-ruido reducida. Una arquitectura con demasiados parámetros puede memorizar sujetos, sesiones o estímulos. Por este motivo, el diseño del modelo debe acompañarse de regularización, particiones rigurosas, múltiples semillas y comparaciones frente a modelos sencillos.

Las CNNs pueden detectar patrones temporales cortos en cada canal o trabajar sobre representaciones tiempo-frecuencia. Esta flexibilidad ha favorecido su uso en clasificación de habla imaginada y en modelos de decodificación del habla [11, 9]. No obstante, cuando se utilizan imágenes construidas artificialmente, el resultado depende de que la organización de los canales tenga un significado espacial adecuado.

Los Transformers permiten relacionar segmentos asociados a distintas palabras y seleccionar los momentos o sensores más informativos. En lugar de asignar un peso fijo a cada canal, un mecanismo de atención espacial puede aprender qué sensores son más relevantes para cada muestra. En decodificación de palabras con MEG, se ha utilizado atención espacial basada en las coordenadas de los sensores antes de aplicar convoluciones temporales [9, 30].

Otra estrategia consiste en añadir *embeddings* que describen cada sensor. La posición, la orientación y el tipo de sensor se transforman en vectores y se suman a la representación de la señal. De esta forma, el modelo no recibe únicamente un índice de canal, sino información sobre el lugar en el que se realizó la medida. Esta idea es especialmente útil para combinar sistemas MEG heterogéneos y puede adaptarse a EEG utilizando las coordenadas de los electrodos.

En una señal cerebral, el número de elementos puede ser muy elevado porque depende del tiempo, los sensores y, en algunos modelos, los niveles de cuantización. Para reducir el coste de la atención, se puede factorizar el cálculo. La atención *criss-cross* procesa por separado las relaciones temporales dentro de cada canal y las relaciones espaciales entre canales en cada instante. MEG-XL utiliza esta estrategia para modelar contextos de dos minutos y medio sin construir una matriz de atención completa sobre todos los tokens [23].

Una arquitectura de este tipo conserva dos ejes distintos. La atención temporal aprende qué momentos de un mismo sensor están relacionados, mientras que la atención espacial aprende qué sensores deben combinarse en un instante determinado. Esta separación resulta natural para datos EEG y MEG, ya que evita comprimir prematuramente toda la estructura multicanal en un único vector.

En decodificación de palabras, el aprendizaje supervisado exige conocer el instante exacto de cada palabra y disponer de suficientes repeticiones. Los conjuntos de datos cerebrales suelen ser mucho más pequeños que los utilizados en visión o procesamiento del lenguaje. Además, registrar muchas horas de una misma persona es costoso y, en aplicaciones clínicas, puede ser inviable.

El aprendizaje autosupervisado permite aprovechar señal sin etiquetas lingüísticas. En señales neuronales, el modelo puede aprender regularidades temporales, relaciones entre canales y propiedades del dispositivo antes de recibir etiquetas de palabras. MEG-XL aplica predicción enmascarada sobre tokens discretos: durante el preentrenamiento, se ocultan bloques temporales completos para todos los sensores y el Transformer debe predecir los códigos originales a partir de los bloques visibles [23]. El enmascaramiento por bloques evita que la tarea se resuelva interpolando únicamente muestras contiguas.

La transferencia entre sujetos pretende que patrones aprendidos con varias personas ayuden a un nuevo participante. La transferencia entre conjuntos introduce, además, diferencias de hardware, protocolo y estímulos. La transferencia de MEG a EEG es todavía más exigente, porque cambia la propia magnitud física registrada.

Para que la transferencia sea efectiva, es necesario distinguir entre componentes generales y específicos. Las primeras capas pueden aprender patrones temporales básicos, mientras que las capas espaciales pueden depender fuertemente del sistema de sensores. Una estrategia consiste en reutilizar el Transformer temporal y adaptar la proyección de canales o los *embeddings* de sensores. Otra posibilidad es ajustar toda la red con una tasa de aprendizaje pequeña, manteniendo una tasa mayor para la nueva cabeza de clasificación.

Asimismo, debe considerarse la transferencia negativa. Un modelo preentrenado puede rendir peor si las representaciones aprendidas no son adecuadas para el nuevo dominio. Por ejemplo, una frecuencia de muestreo, un filtrado o un tokenizer entrenado con una distribución diferente pueden descartar información útil. Por ello, la transferencia debe compararse con un modelo entrenado desde cero utilizando la misma arquitectura y los mismos datos. Solo así puede determinarse si la mejora procede realmente del preentrenamiento.

Los Transformers fueron desarrollados originalmente para secuencias de tokens lingüísticos. En texto, un token es un elemento discreto que identifica una palabra, una subpalabra o un símbolo. Las señales EEG y MEG, en cambio, son continuas. Para aplicar objetivos similares al modelado del lenguaje, se puede transformar la señal en una secuencia de representaciones discretas mediante un tokenizer neuronal.

Un tokenizer aprende un codificador que comprime un fragmento de señal en un vector latente. A continuación, este vector se sustituye por la entrada más próxima de un diccionario o *codebook*. El índice seleccionado actúa como token discreto. Un decodificador intenta reconstruir la señal original a partir de los tokens. Durante el entrenamiento del tokenizer se busca que la reconstrucción conserve la información relevante utilizando una secuencia más corta.

La cuantización vectorial residual, conocida como RVQ, utiliza varios diccionarios de forma jerárquica. El primer nivel aproxima la señal y los siguientes codifican los residuos que quedan después de cada aproximación. Si se utilizan Q niveles, el fragmento queda representado por una secuencia de códigos

$$\mathbf{z} = \left(z^{(1)}, z^{(2)}, \dots, z^{(Q)} \right).$$

Esta descomposición aumenta la capacidad de representación sin necesitar un único vocabulario de tamaño exponencial.

BioCodec es un tokenizer desarrollado para bioseñales y entrenado principalmente con EEG [4]. En MEG-XL se aplica de forma independiente a cada canal y utiliza seis niveles RVQ, un vocabulario de 256 códigos por nivel y un factor de compresión temporal de doce [23]. De esta forma, cada sensor produce varios tokens residuales por instante comprimido.

La tokenización cumple dos funciones. En primer lugar, reduce la longitud temporal y permite procesar contextos mayores con el mismo presupuesto de memoria. En segundo lugar, proporciona un objetivo discreto para la predicción enmascarada. En lugar de reconstruir directamente cada valor continuo, el modelo predice una distribución de probabilidad sobre los códigos del vocabulario.

Sin embargo, esta compresión también puede eliminar información. Un tokenizer entrenado con EEG a una frecuencia concreta no tiene por qué representar de forma óptima MEG, EEG remuestreado a otra frecuencia o bandas espectrales distintas. Por este motivo, la calidad de reconstrucción debe evaluarse en el dominio objetivo. Una reconstrucción visualmente parecida no garantiza que se conserven las características necesarias para clasificar palabras.

Por otro lado, existen tokenizers que comprimen simultáneamente tiempo y canales. Esta estrategia produce secuencias más cortas, pero mezcla información espacial desde el principio. Si el objetivo es transferir entre sistemas con disposiciones de sensores diferentes, esta compresión puede dificultar la adaptación. La tokenización independiente por canal conserva la separación espacial, aunque obliga al Transformer posterior a modelar un número mayor de elementos.

En el contexto de EEG, la selección del tokenizer está relacionada con la frecuencia de muestreo y el filtrado. Si la señal contiene frecuencias que el tokenizer nunca observó durante su entrenamiento, la cuantización puede ser poco precisa. Del mismo modo, reducir demasiado la frecuencia antes de tokenizar puede simplificar la señal a costa de eliminar componentes útiles. La comparación entre tokenizers, frecuencias y estrategias de inicialización constituye, por tanto, una parte importante de la adaptación de modelos MEG a EEG.

2.5 Decodificación contextual de palabras

La clasificación de palabras intenta identificar qué palabra está asociada a un segmento de actividad cerebral. En el caso más sencillo, cada ventana se procesa de forma independiente y el modelo devuelve una distribución sobre un vocabulario fijo. En la decodificación contextual, el modelo recibe varias ventanas consecutivas y produce una predicción para cada una, teniendo en cuenta las relaciones dentro de la secuencia.

Este enfoque se sitúa entre la clasificación aislada y la reconstrucción completa de texto. Sigue trabajando con un vocabulario cerrado y con eventos previamente alineados, pero introduce información lingüística y neural de las palabras vecinas. Esto permite estudiar si el contexto mejora la representación antes de añadir mecanismos más complejos de búsqueda, reordenación o generación de palabras fuera del vocabulario.

2.5.1. Representaciones lingüísticas

Una clasificación convencional representa cada clase mediante un identificador independiente. En este caso, las palabras *perro*, *gato* y *mesa* estarían igual de separadas entre sí, aunque las dos primeras compartan propiedades semánticas. Este planteamiento obliga al modelo a aprender cada palabra como una categoría aislada.

Los *embeddings* lingüísticos representan palabras mediante vectores continuos. Palabras utilizadas en contextos parecidos tienden a ocupar posiciones próximas en el espacio. Los modelos de lenguaje modernos generan representaciones contextuales, de modo que el vector asociado a una palabra también depende de la frase en la que aparece. Esta

propiedad resulta útil para la decodificación cerebral, ya que la respuesta neuronal a una palabra tampoco es completamente independiente de su contexto.

Los enfoques recientes utilizan representaciones extraídas de modelos T5 [32]. Para cada palabra del vocabulario se obtiene un vector de una capa intermedia del modelo de lenguaje. Si una palabra se divide en varios tokens, sus representaciones pueden promediarse para construir un único objetivo a nivel de palabra. El decodificador cerebral no predice directamente una etiqueta, sino un vector que debe aproximarse al *embedding* lingüístico correspondiente [9, 30].

Durante la inferencia, el vector neuronal predicho se compara con los vectores de todas las palabras del conjunto de recuperación. La palabra elegida es la que presenta mayor similitud coseno:

$$\hat{y} = \arg \max_{y \in \mathcal{V}} \frac{\hat{\mathbf{w}}^\top \mathbf{w}_y}{\|\hat{\mathbf{w}}\| \|\mathbf{w}_y\|},$$

donde $\hat{\mathbf{w}}$ es la representación predicha a partir de la señal cerebral, $\mathbf{w}_y$ es la representación de la palabra y y $\mathcal{V}$ es el vocabulario.

Este planteamiento permite aprovechar la estructura semántica aprendida por el modelo de lenguaje. Una predicción incorrecta puede quedar cerca de palabras relacionadas en lugar de ser completamente arbitraria. Además, la misma arquitectura puede adaptarse a vocabularios diferentes cambiando el conjunto de vectores de recuperación. No obstante, el modelo continúa limitado por las palabras incluidas en dicho conjunto.

El tamaño del vocabulario introduce un compromiso. Un vocabulario pequeño contiene menos opciones y facilita la clasificación, pero cubre una parte menor del texto. Un vocabulario grande se aproxima mejor al lenguaje natural, aunque reduce la precisión y necesita más ejemplos por clase. LibriBrain evalúa la clasificación sobre las 250 palabras más frecuentes, que cubren una proporción importante del contenido del corpus [30]. MEG-XL utiliza también conjuntos más reducidos en algunos experimentos para analizar el rendimiento en escenarios con pocos datos [23].

La frecuencia de las palabras es otro factor importante. Las palabras funcionales, como artículos y preposiciones, aparecen muchas veces y suelen clasificarse mejor que palabras de contenido menos frecuentes. Por ello, una precisión global puede estar dominada por unas pocas clases frecuentes. Las métricas equilibradas y los análisis por frecuencia ayudan a comprobar si el modelo aprende todo el vocabulario o únicamente las palabras más repetidas.




Figura 2.8: Esquema de clasificación contextual de palabras. Cada evento lingüístico define una ventana cerebral; las representaciones locales se contextualizan y se proyectan al espacio de un modelo de lenguaje para recuperar las palabras más próximas.

2.5.2. Aprendizaje contrastivo

El aprendizaje contrastivo busca acercar representaciones correspondientes y separar representaciones no relacionadas. En la clasificación de palabras, cada segmento cerebral

y su palabra real forman un par positivo. Las demás palabras del lote pueden utilizarse como ejemplos negativos. El modelo aprende un espacio común en el que la representación neuronal se aproxima a su objetivo lingüístico.

Si $\mathbf{r}_i$ es la representación cerebral del ejemplo i y $\mathbf{w}_j$ es el *embedding* de la palabra j , se puede construir una matriz de similitudes

$$s_{ij} = \frac{\mathbf{r}_i^\top \mathbf{w}_j}{\|\mathbf{r}_i\| \|\mathbf{w}_j\|}.$$

Los elementos de la diagonal corresponden normalmente a pares positivos y el resto actúa como negativos. La *loss* aumenta la similitud de los positivos y reduce la de los negativos.

Una dificultad aparece cuando una misma palabra se repite dentro del lote. Dos segmentos asociados a la palabra *the*, por ejemplo, no deberían considerarse negativos entre sí. Las variantes de SigLIP utilizadas en decodificación de palabras introducen máscaras para evitar que las repeticiones se penalicen incorrectamente [44, 9]. MEG-XL emplea D-SigLIP durante el ajuste fino para predecir representaciones T5 [23].

El aprendizaje contrastivo presenta varias ventajas. No obliga a utilizar una capa de clasificación con un tamaño fijo, incorpora relaciones entre palabras y permite reutilizar representaciones lingüísticas preentrenadas. Igualmente favorece el aprendizaje de una geometría común entre dos dominios muy diferentes: la señal cerebral y el lenguaje.

Sin embargo, la elección de negativos afecta considerablemente al entrenamiento. Si los negativos son demasiado fáciles, el modelo puede aprender diferencias generales sin distinguir palabras parecidas. Si contienen falsos negativos, se penalizan relaciones válidas. El tamaño del lote, la temperatura de la similitud y el equilibrio de clases también influyen en el resultado.

El contexto se incorpora antes de aplicar la *loss*. Cada ventana cerebral se codifica localmente y las representaciones de varias palabras consecutivas se introducen en un Transformer bidireccional. La salida correspondiente a cada posición contiene información de toda la secuencia. Después, cada una se compara con el *embedding* lingüístico de su palabra. De este modo, el modelo aprende simultáneamente relaciones neuronales entre ventanas y relaciones semánticas entre palabras.

2.5.3. Evaluación de la clasificación de palabras

La evaluación de un clasificador de palabras debe reflejar la dificultad del vocabulario y su distribución. La precisión Top-1 considera correcta una muestra únicamente cuando la palabra real ocupa la primera posición. La precisión Top- k considera correcta la muestra si la palabra aparece entre las k predicciones con mayor puntuación. En señales cerebrales, donde existe una incertidumbre elevada, Top-5 o Top-10 permiten medir si el modelo recupera un conjunto reducido de candidatos plausibles.

Si el vocabulario contiene V palabras y todas las clases tienen la misma probabilidad, el nivel de azar para Top- k es aproximadamente

$$\text{Azar}_{\text{Top-}k} = \frac{k}{V}.$$

Por ejemplo, con 250 palabras, la probabilidad aleatoria de incluir la palabra correcta entre diez candidatos es $10/250 = 0,04$. Esta referencia debe acompañar siempre a los resultados, aunque una línea base aleatoria basada en la distribución real puede ser más adecuada cuando las clases están desbalanceadas.

La precisión equilibrada calcula primero el rendimiento de cada clase y después obtiene su media. Para Top- k , puede expresarse como

$$BA_{\text{Top-}k} = \frac{1}{V} \sum_{v=1}^V \frac{\text{aciertos Top-}k \text{ de la clase } v}{\text{número de ejemplos de la clase } v}.$$

Esta métrica evita que las palabras más frecuentes dominen el resultado. Por este motivo, la precisión Top-10 equilibrada se ha convertido en una métrica habitual en clasificación contextual de palabras con MEG [30, 23].

Los resultados deben calcularse sobre datos no utilizados para ajustar el modelo ni seleccionar hiperparámetros. En estudios con varios sujetos es importante aclarar si la evaluación es dependiente o independiente del sujeto. En el primer caso, el modelo ha observado datos de esa persona durante el entrenamiento. En el segundo, se evalúa su capacidad para generalizar a participantes completamente nuevos. Esta segunda condición es más exigente y se aproxima mejor a una aplicación clínica.

Además, deben evitarse fugas entre estímulos. Si la misma narración aparece en entrenamiento y prueba para sujetos distintos, el modelo puede reconocer características del audio, la duración o el orden de las palabras. Una partición rigurosa mantiene el mismo estímulo en una única división. Del mismo modo, las ventanas solapadas de una grabación no deben repartirse entre entrenamiento y prueba.

Una evaluación fiable incluye comparaciones con varias líneas base. La primera es el nivel de azar. La segunda puede consistir en sustituir la señal cerebral por ruido aleatorio o permutar las correspondencias entre señal y palabra. Estos controles permiten comprobar si el modelo utiliza realmente información neuronal. Asimismo, es conveniente comparar la arquitectura preentrenada con la misma arquitectura inicializada aleatoriamente. De esta forma se separa el efecto del preentrenamiento del efecto de la capacidad del modelo.

La variabilidad entre ejecuciones debe reflejarse mediante varias semillas y medidas de dispersión, como desviación típica o error estándar. Para determinar si una mejora supera el azar se pueden utilizar pruebas de permutación. Cuando se comparan dos modelos sobre los mismos ejemplos, las pruebas deben tener en cuenta que las predicciones no son independientes.

Además del resultado agregado, es útil analizar el rendimiento por frecuencia, categoría gramatical, sujeto y conjunto de datos. Estos análisis pueden revelar que la mejora se concentra en palabras frecuentes o en unos pocos participantes. También permiten estudiar si el contexto beneficia por igual a sustantivos, verbos y palabras funcionales.

Por último, las métricas cambian cuando se pasa de clasificación de palabras a reconstrucción de secuencias. En sistemas *brain-to-text* se utilizan medidas como tasa de error de palabra, tasa de error de carácter, BLEU, ROUGE o similitud semántica. Estas métricas evalúan la secuencia completa y pueden incorporar un modelo de lenguaje para reordenar o completar candidatos. Sin embargo, un buen resultado de secuencia no demuestra por sí solo que la señal cerebral sea informativa, ya que el modelo lingüístico puede corregir gran parte de la salida. Por ello, incluso en sistemas completos, siguen siendo necesarios controles con ruido, permutaciones y evaluación directa de la clasificación neuronal [21].

En conjunto, la clasificación contextual de palabras proporciona un marco controlado para estudiar la transferencia de representaciones entre MEG y EEG. Permite mantener una tarea, un espacio lingüístico y unas métricas comunes mientras se modifican la modalidad, el preprocesamiento, la frecuencia de muestreo, el tokenizer o la estrategia de inicialización. Esta separación facilita identificar qué componentes contribuyen realmente a la adaptación y qué limitaciones proceden de la calidad y cantidad de los datos.

2.6 Estado del arte

En esta sección se revisan los trabajos que han tratado de recuperar información lingüística a partir de registros cerebrales no invasivos. Esta revisión se hace con el objetivo de identificar la evolución de los métodos más próximos al problema abordado en este trabajo: la clasificación contextual de palabras, el aprendizaje de representaciones neuronales preentrenadas y la transferencia entre MEG y EEG.

La comparación entre trabajos debe realizarse con precaución. Como hemos explicado en apartados anteriores, bajo la denominación de decodificación del lenguaje se agrupan tareas muy diferentes:

- distinguir unas pocas vocales imaginadas,
- identificar un segmento de audio entre varios candidatos,
- recuperar una palabra de un vocabulario cerrado o
- generar una frase completa.

También varían por otro lado:

- la modalidad de registro,
- el número de sujetos,
- la duración disponible por persona,
- la forma de presentar el estímulo y
- el criterio utilizado para separar entrenamiento y prueba.

Por ello, los resultados numéricos solo son comparables cuando se mantienen constantes estas condiciones.

2.6.1. Decodificación no invasiva del lenguaje

La investigación en decodificación no invasiva del lenguaje ha avanzado desde experimentos muy controlados hacia escenarios progresivamente más naturales. Los primeros trabajos se centraban principalmente en unidades aisladas y vocabularios pequeños, ya que este planteamiento facilita la repetición de estímulos y permite utilizar clasificadores convencionales. Los métodos recientes, en cambio, intentan trabajar con habla o lectura continua, relacionar la actividad cerebral con representaciones obtenidas mediante modelos de lenguaje y aprovechar el contexto de las palabras anteriores y posteriores.

En esta evolución pueden distinguirse tres niveles. El primero consiste en detectar información general, como la presencia de habla o la identidad de un fonema. El segundo busca clasificar palabras o segmentos dentro de un conjunto de candidatos. El tercero pretende reconstruir secuencias completas mediante un sistema *brain-to-text*. Este último nivel es el más próximo a una interfaz de comunicación, aunque también es el más difícil de evaluar, porque un modelo de lenguaje externo puede generar frases plausibles incluso cuando la señal cerebral contiene poca información. En consecuencia, la clasificación de palabras continúa siendo una tarea intermedia útil para estudiar cuánto contenido lingüístico puede recuperarse realmente de la señal.

Decodificación mediante EEG

Una parte importante de la literatura basada en EEG se ha dedicado al habla imaginada. En estos experimentos se solicita a los participantes que imaginen la pronunciación

de vocales, sílabas, palabras o comandos sin producir sonido. Las primeras propuestas combinaron características temporales, espectrales o tiempo-frecuencia con clasificadores como LDA, SVM o *random forest*. Posteriormente se incorporaron redes convolucionales y recurrentes para aprender las características directamente a partir de la señal [31, 2].

Los resultados obtenidos en este ámbito muestran que es posible diferenciar un número reducido de clases en condiciones controladas, especialmente cuando se entrena y evalúa un modelo específico para cada sujeto. Por ejemplo, se han utilizado CNNs para clasificar las cinco vocales imaginadas y distintos comandos direccionales, aunque el rendimiento cambia considerablemente entre participantes y conjuntos de datos [36, 33]. Estas diferencias dificultan extraer conclusiones generales. Un porcentaje elevado en una clasificación de dos o cinco clases no implica que el sistema pueda extenderse a un vocabulario amplio, ni que mantenga su funcionamiento con personas o sesiones no observadas durante el entrenamiento.

La lectura natural proporciona un escenario diferente. En este caso no se pide al participante que genere internamente una palabra concreta, sino que se registra su actividad mientras procesa un texto. El conjunto de datos ZuCo permitió avanzar en esta dirección al combinar EEG de alta densidad con seguimiento ocular. Las fijaciones indican qué palabra está observando el participante y permiten asociar intervalos de señal a elementos concretos de una frase [19]. Esta alineación ha facilitado el desarrollo de modelos que reciben una secuencia de representaciones EEG a nivel de palabra e intentan reconstruir el texto leído.

Wang y Ji propusieron uno de los primeros sistemas de vocabulario abierto sobre ZuCo. Su método utiliza las representaciones EEG como entrada de un modelo basado en BART y plantea conjuntamente la traducción EEG-texto y la clasificación de sentimiento [41]. Más adelante, DeWave introdujo una codificación discreta de las ondas EEG antes de conectarlas con un decodificador lingüístico, con el objetivo de reducir la distancia entre una señal continua y la representación utilizada por un modelo de lenguaje [14]. Estos trabajos fueron relevantes porque desplazaron el problema desde una clasificación cerrada hacia la generación de secuencias completas.

Sin embargo, una revisión posterior mostró que los resultados de varios sistemas EEG-to-text estaban afectados por la forma de realizar la evaluación. En particular, el uso implícito de *teacher forcing* permitía que el decodificador recibiera palabras correctas de la secuencia durante la inferencia. Al eliminar esta ayuda y comparar el sistema con entradas de ruido, el rendimiento podía ser similar al obtenido sin información EEG [25]. Esta observación no invalida el uso de ZuCo ni la investigación sobre lectura natural, pero sí obliga a separar la capacidad lingüística del decodificador de la información que aporta realmente la señal cerebral.

Otro resultado importante procede del estudio de Sato et al., que reunió 175 horas de EEG de un único participante leyendo texto en voz alta. El modelo se entrenó mediante aprendizaje contrastivo entre segmentos EEG y audio y alcanzó un rendimiento muy superior al obtenido al limitar el entrenamiento a unas diez horas [35]. El trabajo demuestra que la profundidad de datos por sujeto puede producir una mejora muy grande. No obstante, la tarea consiste en identificar segmentos de habla producida de cinco segundos y no palabras durante lectura silenciosa. Además, aunque se incorporan controles frente a la actividad muscular, el habla pronunciada introduce una fuente de información que no está presente en la percepción o en la lectura natural.

El trabajo de d'Ascoli et al. amplió la escala de la comparación al reunir registros EEG y MEG de cientos de participantes expuestos a millones de palabras en tareas de lectura y escucha [9]. Sus resultados muestran que una arquitectura común puede recuperar representaciones de palabras en varios idiomas y dispositivos. Al mismo tiempo, el es-

tudio señala dos diferencias relevantes para este trabajo: el rendimiento es mayor con MEG que con EEG y, manteniendo el contenido lingüístico, la lectura resulta más fácil de decodificar que la escucha. También se observa que la cantidad de datos disponible por participante tiene un efecto importante, lo que coincide con la tendencia encontrada en los registros EEG de larga duración.

En conjunto, la decodificación mediante EEG presenta dos líneas que todavía no se han unido de forma satisfactoria. Por una parte, existen clasificadores de habla imaginada capaces de distinguir vocabularios pequeños, pero suelen ser dependientes del sujeto y del protocolo. Por otra, los sistemas de lectura natural intentan generar texto abierto, aunque su evaluación puede estar dominada por el modelo lingüístico. Entre ambos extremos queda la clasificación contextual de palabras, que permite utilizar estímulos naturales y, al mismo tiempo, medir directamente la contribución de la señal cerebral. La disponibilidad de EEG, su menor coste y su portabilidad hacen que esta tarea resulte especialmente interesante, pero la baja relación señal-ruido y la heterogeneidad de los montajes continúan limitando su rendimiento.

Decodificación mediante MEG

La MEG se ha utilizado con menor frecuencia que EEG debido al coste y a la menor disponibilidad de los sistemas de adquisición. No obstante, la mayor calidad espacial de sus registros y la ausencia de una referencia eléctrica han favorecido resultados más consistentes en decodificación del lenguaje. Los primeros estudios, al igual que en EEG, se centraron en clasificaciones cerradas. Dash et al. analizaron cinco frases imaginadas y pronunciadas por ocho participantes. Mediante CNNs aplicadas a características espaciales, temporales y espectrales, obtuvieron resultados elevados dentro de ese conjunto reducido de frases [10]. El experimento mostró que la MEG contiene información discriminativa sobre la producción y la imaginación del habla, aunque el vocabulario cerrado y el número de participantes no permiten extrapolar esos porcentajes a una transcripción natural.

Un cambio de enfoque se produjo con la utilización de objetivos contrastivos. Défossez et al. entrenaron un codificador neuronal para acercar segmentos M/EEG a representaciones del audio escuchado [11]. En lugar de asignar una etiqueta lingüística fija, el sistema debía identificar el fragmento de audio correspondiente entre varios candidatos. La arquitectura incorporaba atención espacial para trabajar con diferentes disposiciones de sensores, capas específicas de sujeto y convoluciones dilatadas. Este planteamiento demostró que las representaciones obtenidas por modelos de audio preentrenados constituyen objetivos útiles para la percepción del habla. Sin embargo, el método necesita disponer del audio candidato y no produce directamente palabras o texto.

La publicación de conjuntos de datos de habla continua ha permitido aumentar la escala de estos experimentos. Armeni et al. registraron aproximadamente diez horas por participante durante la escucha de una narración, mientras que MEG-MASC reunió historias naturales repetidas en varios sujetos [3, 17]. Más recientemente, LibriBrain ha proporcionado más de 52 horas de MEG de una sola persona escuchando audiolibros en inglés, con anotaciones temporales de habla, fonemas y palabras [30]. Sus líneas base confirman que el rendimiento aumenta al incorporar más horas de entrenamiento y que los conjuntos profundos, aunque tengan pocos sujetos, son especialmente útiles para estudiar tareas lingüísticas complejas.

Sobre estos datos se ha consolidado la clasificación contextual de palabras. En lugar de procesar cada ventana de forma independiente, las representaciones neuronales asociadas a varias palabras consecutivas se introducen en un Transformer. El modelo puede

así utilizar la estructura de la frase y las dependencias presentes en la señal cerebral. El trabajo de d'Ascoli et al. obtuvo una mejora clara respecto a un codificador local y estableció una referencia común basada en la recuperación de *embeddings* lingüísticos [9]. Esta propuesta se describe con mayor detalle más adelante, ya que constituye la tarea utilizada para ajustar y evaluar MEG-XL.

El paso desde palabras aisladas hacia secuencias completas se aborda en *Unlocking Non-Invasive Brain-to-Text*. En este trabajo, las distribuciones de candidatos producidas por un clasificador de palabras se combinan con un modelo de lenguaje durante una búsqueda en haz. Además, se introduce un detector de palabras fuera del vocabulario y un mecanismo de rellenado contextual [21]. Los autores muestran que el reordenamiento lingüístico y la combinación selectiva de conjuntos de datos mejoran las métricas de secuencia y superan controles aleatorios más estrictos que los utilizados en algunos trabajos anteriores. Aun así, el sistema sigue dependiendo de un vocabulario de recuperación inicial y su calidad está limitada por la precisión del codificador neuronal.

Otro avance reciente (29 de junio de 2026) en la reconstrucción de secuencias completas es Brain2Qwerty v2, que decodifica registros continuos de MEG obtenidos mientras los participantes escriben frases en un teclado [?]. A diferencia de la primera versión del sistema, el modelo no necesita conocer previamente el instante de cada pulsación. Su arquitectura combina un codificador convolucional, un Conformer entrenado mediante CTC, un alineamiento contrastivo entre segmentos neuronales y representaciones de palabras, y un modelo de lenguaje adaptado para reconstruir la frase completa. Con aproximadamente diez horas de registro por participante, alcanza una tasa media de error por palabra del 39,

Aunque este resultado representa uno de los rendimientos más elevados obtenidos en reconstrucción no invasiva de frases, la tarea difiere de la percepción o la lectura estudiadas en este trabajo. Los participantes ejecutan movimientos reales de los dedos y una parte considerable de la información decodificada procede de regiones motoras relacionadas con la planificación y ejecución de las pulsaciones. Por tanto, Brain2Qwerty demuestra la capacidad de la MEG para reconstruir secuencias naturales en condiciones continuas, pero sus métricas no son directamente comparables con la clasificación de palabras percibidas o leídas. Por otro lado, ha salido tan recientemente que no se ha tenido oportunidad de probarlo ni de compararlo con MEG-XL, aunque la arquitectura de codificación y el objetivo contrastivo son similares.

La evolución de la decodificación mediante MEG muestra, por tanto, que el contexto y la cantidad de datos son dos factores fundamentales. Las ventanas locales permiten recuperar información acústica o léxica, pero las secuencias de palabras mejoran el resultado. Del mismo modo, los conjuntos con muchas horas por participante producen mejores modelos que aquellos que distribuyen el mismo tiempo entre un número muy elevado de personas. La principal desventaja es que la mayor parte de estos resultados se ha obtenido con equipos MEG concretos y en condiciones de laboratorio. Para que sus avances puedan trasladarse a una BCI más accesible es necesario determinar qué representaciones pueden conservarse al cambiar a EEG.

2.6.2. Modelos preentrenados de señales cerebrales

El aprendizaje supervisado utilizado en los primeros decodificadores obliga a disponer de una etiqueta para cada segmento. En lenguaje, esto requiere una sincronización precisa con palabras, fonemas o fragmentos de audio. El preentrenamiento autosupervisado intenta reducir esta dependencia aprendiendo primero regularidades generales de

la señal y adaptando después el modelo a una tarea lingüística concreta. Esta estrategia ha dado lugar a los denominados modelos fundacionales de señales cerebrales.

La idea común consiste en reunir datos procedentes de diferentes sujetos y experimentos, dividir la señal en fragmentos o tokens y definir una tarea que no necesite anotaciones manuales. Entre los objetivos habituales se encuentran la reconstrucción de intervalos enmascarados, la predicción de representaciones latentes y la cuantización de la señal. El modelo preentrenado se ajusta después a tareas de clasificación, detección o regresión utilizando una cantidad menor de datos etiquetados. El éxito de esta transferencia depende de que las propiedades aprendidas durante el preentrenamiento sean útiles en el nuevo dominio.

Modelos para EEG

La mayoría de los modelos fundacionales iniciales se desarrolló para EEG, ya que existen más bases de datos públicas y la adquisición es más accesible. LaBraM utiliza predicción enmascarada de parches para aprender representaciones genéricas a partir de un corpus EEG de gran tamaño [24]. EEGPT adopta igualmente un Transformer preentrenado, con el objetivo de conservar dependencias espaciales y temporales que puedan reutilizarse en distintos conjuntos y tareas [39]. Ambos trabajos muestran que el preentrenamiento puede mejorar determinados problemas de clasificación, aunque sus evaluaciones se concentran principalmente en aplicaciones clínicas y paradigmas BCI distintos del lenguaje continuo.

CBraMod introduce una arquitectura de atención *criss-cross* para tratar por separado las relaciones temporales y las relaciones entre canales [40]. Esta factorización reduce el coste respecto a una atención completa y respeta la estructura bidimensional de la señal. El modelo resulta especialmente próximo a MEG-XL desde el punto de vista arquitectónico, pero fue diseñado y evaluado como un modelo general de EEG. Sus ventanas de preentrenamiento continúan siendo mucho más cortas que la escala temporal de una narración.

Otra línea se centra en aprender tokens discretos. BioCodec adapta los códecs neuronales a bioseñales y utiliza cuantización vectorial residual para comprimir cada canal en una secuencia de códigos [4]. El tokenizer puede reutilizarse como representación congelada o como objetivo de una tarea enmascarada. Esta separación entre tokenizer y modelo contextual permite que cada componente se entrene con datos distintos. De hecho, MEG-XL utiliza BioCodec, aunque el tokenizer original fue entrenado con EEG. Este resultado sugiere que algunas regularidades temporales de bajo nivel pueden compartirse entre modalidades, pero no demuestra por sí solo que un modelo contextual aprendido con MEG pueda transferirse a EEG.

BrainOmni aborda de forma explícita la heterogeneidad entre EEG y MEG. Su BrainTokenizer incorpora la posición, orientación y tipo de sensor para cuantizar registros procedentes de equipos distintos. A partir de estos tokens, el modelo se preentrena conjuntamente con miles de horas de EEG y cientos de horas de MEG [43]. Esta propuesta constituye un antecedente directo de la transferencia multimodal, porque intenta construir un espacio común para ambas modalidades. No obstante, su objetivo es proporcionar una representación general para múltiples tareas y no estudiar de forma específica la clasificación contextual de palabras durante lectura natural.

Además de estos modelos generales, se ha estudiado el preentrenamiento orientado al habla. *The Brain's Bitter Lesson* compara diferentes objetivos autosupervisados y concluye que las tareas genéricas pueden escalar mejor que los objetivos supervisados estrechamente vinculados a una etiqueta concreta [22]. La mejora obtenida al aumentar

la cantidad de datos sin etiquetar apoya la utilización de grandes corpus cerebrales antes del ajuste fino. Sin embargo, las ventanas utilizadas por este tipo de modelos suelen abarcar segundos y no minutos, por lo que no aprenden necesariamente a seleccionar dependencias lingüísticas de largo alcance.

En general, los modelos preentrenados de EEG han mejorado la reutilización entre sujetos y conjuntos, pero sus ventajas no son uniformes. El cambio de número de canales, frecuencia de muestreo, referencia y montaje puede exigir adaptadores específicos. Además, un modelo que funciona bien en sueño, epilepsia o imaginación motora no tiene por qué conservar la información necesaria para distinguir palabras. La evaluación sobre una tarea lingüística y frente a una inicialización aleatoria resulta, por tanto, imprescindible para comprobar que la transferencia aporta una mejora real.

D'Ascoli et al. (MEG)

El trabajo de d'Ascoli et al. no es un modelo preentrenado en sentido estricto. Se incluye en esta sección porque define el principal modelo supervisado de referencia para MEG-XL y formaliza la tarea de clasificación contextual de palabras que se adapta en este trabajo [9]. La propuesta se entrenó sobre varios conjuntos EEG y MEG que, en conjunto, incluían cientos de participantes, diferentes idiomas y tareas de lectura y escucha.

Cada ejemplo se construye a partir de una ventana de tres segundos alineada con el inicio de una palabra. En primer lugar, un módulo de atención espacial combina los sensores teniendo en cuenta sus posiciones. Después se aplica una transformación dependiente del sujeto y una sucesión de bloques convolucionales dilatados. Este codificador produce una representación local para cada ventana. Las representaciones de todas las palabras de una oración se ordenan y se introducen en un Transformer bidireccional, de forma que la predicción de una posición pueda utilizar el contexto neuronal del resto de la frase.

El objetivo no consiste en predecir directamente una clase, sino en aproximar un *embedding* de la palabra obtenido con T5. Para entrenar el espacio común se utiliza D-SigLIP, una modificación de SigLIP que evita penalizar como negativos dos ejemplos asociados a la misma palabra. Durante la evaluación, la representación predicha se compara por similitud coseno con un conjunto de recuperación. El resultado principal se expresa mediante precisión Top-10 equilibrada sobre las 250 palabras más frecuentes de cada conjunto.

La incorporación del Transformer contextual produce una mejora media cercana al 50 % respecto al codificador que procesa las palabras de forma aislada. El estudio también muestra que el rendimiento aumenta con la cantidad de datos de entrenamiento y con el promedio de varias repeticiones. Al comparar protocolos, MEG supera claramente a EEG y la lectura supera a la escucha cuando se presentan las mismas frases. Asimismo, se observa que dedicar más tiempo a cada participante puede resultar más útil que repartir el presupuesto de grabación entre muchos sujetos con pocas sesiones.

Pese a estos avances, el modelo necesita anotaciones lingüísticas y se entrena de forma supervisada desde cero para la tarea. Su contexto queda limitado a la oración presentada y no aprende previamente las regularidades de grabaciones continuas sin etiquetas. La capa dependiente del sujeto facilita el entrenamiento conjunto, pero complica la adaptación a una persona completamente nueva. Por último, la evaluación principal se realiza sobre un vocabulario frecuente y cerrado. Estos límites explican por qué el trabajo constituye una referencia sólida para el ajuste fino, pero no resuelve el problema de aprender con pocos datos del sujeto objetivo.

MEG-XL

Gran parte de este trabajo se sustenta en la existencia y éxito que ha tenido MEG-XL. Éste parte de la hipótesis de que el contexto útil de una señal cerebral no se limita a la duración de la unidad que se desea clasificar. La respuesta a una palabra puede depender de la frase, del discurso, del estado del participante y de propiedades estables de la sesión. Sin embargo, la mayoría de los modelos preentrenados procesa ventanas de entre medio segundo y treinta segundos. MEG-XL amplía esta escala y utiliza muestras continuas de dos minutos y medio, entre cinco y trescientas veces más largas que las empleadas por modelos anteriores [23]. El objetivo de esta arquitectura es tener un modelo relativamente pequeño (30M de parámetros) que pueda aprender representaciones de contexto largo y transferirlas a tareas lingüísticas con pocos datos.




Figura 2.9: Resumen del preentrenamiento y del ajuste fino de MEG-XL. El modelo aprende primero a reconstruir tokens cerebrales en contextos largos y posteriormente reutiliza esas representaciones en una tarea contrastiva de clasificación contextual de palabras. Adaptado conceptualmente de Jayalath y Parker Jones.

El preentrenamiento se realiza sobre aproximadamente 300 horas de MEG y más de 800 participantes, combinando grabaciones de reposo, tareas sensoriomotoras y experimentos de lenguaje. La señal se remuestrea a 50 Hz utilizando un ancho de banda de 0.1–40Hz (incumpliendo la frecuencia de Nyquist), después se tokeniza canal a canal mediante BioCodec. Este tokenizer reduce la dimensión temporal y produce códigos discretos mediante cuantización vectorial residual. A cada token se añaden representaciones de la posición del sensor y de su tipo, diferenciando magnetómetros y gradiómetros.

Sobre estos tokens se aplica un Transformer con atención *criss-cross*. La atención temporal relaciona instantes dentro de un mismo sensor, mientras que la atención espacial combina sensores en un mismo momento. De esta forma se evita construir una matriz de atención completa sobre todos los canales y tiempos. Durante el entrenamiento se ocultan bloques temporales contiguos para todos los sensores y el modelo debe recuperar sus tokens. El enmascaramiento de bloques largos reduce la posibilidad de resolver la tarea mediante una interpolación local y obliga a utilizar información más distante.

Para la evaluación lingüística, MEG-XL se ajusta sobre LibriBrain, Armeni y MEG-MASC. La tarea sigue el planteamiento de d’Ascoli et al.: se procesan secuencias de ventanas alineadas con palabras y se predicen *embeddings* T5 mediante D-SigLIP. Los experimentos muestran que el modelo preentrenado ofrece su mayor ventaja cuando hay pocos datos del sujeto objetivo. En algunos escenarios alcanza un rendimiento comparable al modelo supervisado utilizando alrededor de una hora en lugar de decenas de horas. Cuando se dispone de un registro muy profundo de una sola persona, el modelo supervisado puede recuperar la diferencia, lo que indica que el preentrenamiento sustituye principalmente a la falta de datos individuales.

El análisis de la longitud de contexto muestra además que las representaciones mejoran cuando el modelo ha sido preentrenado con ventanas más largas. No basta con pro-

porcionar una secuencia extensa durante la inferencia: el modelo debe haber aprendido previamente a seleccionar qué regiones lejanas son relevantes. Las capas iniciales tienden a utilizar relaciones locales y las posteriores amplían progresivamente su alcance, lo que sugiere una integración jerárquica del contexto.

MEG-XL supone el antecedente e inspiración más próximo a este trabajo, pero mantiene varias limitaciones. El preentrenamiento y la evaluación se realizan con MEG, la tarea final se restringe a habla percibida y parte de los experimentos utiliza un vocabulario de 50 palabras. El modelo tampoco estudia la adaptación a montajes EEG, donde cambian la referencia, la geometría, el número de canales, la amplitud y la distribución del ruido. Aunque BioCodec fue entrenado originalmente con EEG, el resto de las representaciones contextuales se aprende sobre MEG. Por tanto, queda abierta la cuestión de si ese conocimiento temporal y espacial puede transferirse a EEG durante lectura natural.




Figura 2.10: Evolución simplificada de los trabajos más próximos a la decodificación no invasiva de lenguaje considerada en esta memoria. La progresión combina vocabularios mayores, contexto más largo, más datos por participante y modelos lingüísticos externos.

2.6.3. Limitaciones de los trabajos existentes

La primera limitación común es la cantidad y distribución de los datos. Muchos conjuntos reúnen un número elevado de participantes, pero cada uno aporta menos de dos horas. Este formato permite estudiar generalización entre sujetos, aunque dificulta entrenar modelos profundos sobre patrones individuales. Los conjuntos de larga duración muestran que el rendimiento continúa creciendo al añadir horas por persona [35, 30, 9]. Sin embargo, registrar decenas de horas para cada nuevo usuario no es una solución práctica, especialmente en una aplicación clínica.

La segunda limitación es la variabilidad entre dominios. Dos conjuntos EEG pueden diferir en referencia, número de electrodos, frecuencia de muestreo, impedancias, filtros y sistema de coordenadas. Al cambiar de EEG a MEG se modifica además la magnitud física registrada. Los módulos de atención espacial, las máscaras de sensores y los *embeddings* de posición reducen parte de esta heterogeneidad, pero no garantizan que una representación aprendida en una modalidad conserve su utilidad en la otra. BrainOmni constituye un primer intento de unificación, aunque todavía no se ha demostrado una transferencia específica de un modelo MEG de contexto largo hacia clasificación de palabras con EEG.

La tercera limitación procede de las diferencias entre tareas. La actividad registrada durante habla producida contiene componentes motores y musculares que no aparecen durante escucha o lectura silenciosa. La lectura mediante presentación rápida de palabras facilita la alineación, pero no reproduce el comportamiento natural de los ojos. La lectura libre es más realista, aunque requiere seguimiento ocular y genera fijaciones de duración variable, regresiones y palabras omitidas. En consecuencia, un modelo entrena-

do con escucha continua no puede aplicarse directamente a lectura natural sin adaptar la construcción de ventanas y la interpretación de los eventos.

También existe una limitación temporal. Los modelos de clasificación tradicionales procesan intervalos aislados y descartan la información anterior y posterior. Los Transformers contextuales incorporan frases completas, pero siguen trabajando con secuencias preparadas para una tarea supervisada. Los modelos fundacionales, por su parte, suelen preentrenarse con ventanas cortas. MEG-XL demuestra que aprender con minutos de señal puede mejorar la transferencia, aunque todavía no se conoce qué parte de esta mejora corresponde a contexto lingüístico, estabilidad del sujeto, características de la sesión o regularidades del dispositivo.

La evaluación constituye otro punto crítico. Las métricas de generación pueden aumentar gracias a las probabilidades de un modelo de lenguaje, aunque la entrada cerebral sea poco informativa. El uso de *teacher forcing*, la repetición de frases entre particiones o la selección de hiperparámetros sobre el conjunto de prueba pueden producir resultados excesivamente optimistas [25]. Por ello, se requieren líneas base con ruido, permutación de etiquetas, separación por estímulos y comparación entre la misma arquitectura inicializada aleatoriamente y preentrenada. En clasificación de palabras también debe indicarse el tamaño del vocabulario y utilizar métricas equilibradas para que las palabras frecuentes no dominen el resultado.

El vocabulario cerrado continúa siendo una restricción importante. La recuperación entre 50 o 250 palabras permite medir avances de forma controlada, pero está lejos de una comunicación abierta. Los mecanismos de reordenamiento e inserción mediante modelos de lenguaje amplían la cobertura [21], aunque introducen el riesgo de que la coherencia lingüística oculte errores del decodificador cerebral. Antes de avanzar hacia una generación completamente abierta resulta necesario mejorar la representación neuronal y demostrar que cada incremento de rendimiento procede de la señal.

Por último, los trabajos actuales suelen estudiar por separado el preentrenamiento, la clasificación de palabras y la transferencia entre modalidades. Los modelos generales de EEG no se diseñan específicamente para lenguaje; el modelo contextual de d'Ascoli et al. necesita muchos datos etiquetados; y MEG-XL no ha sido evaluado con EEG. Esta separación define el hueco abordado en el presente trabajo. Lo que este trabajo propone es mantener la tarea y la arquitectura de clasificación contextual, incorporar conjuntos EEG de lectura y percepción, y comparar inicializaciones desde cero y preentrenadas. De este modo puede evaluarse si las representaciones de contexto largo aprendidas con MEG aportan una ventaja real al cambiar de modalidad o si, por el contrario, las diferencias físicas y experimentales producen transferencia negativa.

CAPÍTULO 3

Datasets utilizados

Como se ha descrito anteriormente, una de las limitaciones de la decodificación cerebral no invasiva es la disponibilidad de datos. La adquisición de EEG y sobre todo de MEG requiere equipamiento especializado, tiempo de preparación y la participación de voluntarios en sesiones que pueden resultar largas. Además, los conjuntos de datos disponibles presentan diferencias importantes en el número y la posición de los sensores, la frecuencia de muestreo, el idioma, la tarea realizada y la cantidad de información disponible por participante.

En este trabajo era necesario combinar varios conjuntos de datos para aumentar la cantidad y la diversidad de registros disponibles. No obstante, diferentes datasets desempeñan distintas funciones dentro del proceso experimental. Los conjuntos de lectura y escucha se emplean para entrenar la adaptación de MEG-XL a esta nueva modalidad. Finalmente, OpenNeuro ds004408 se reserva para realizar el *fine-tuning* supervisado y evaluar la clasificación de palabras durante la escucha de habla continua.

Los cuatro conjuntos utilizados en entrenamiento se dividen en dos grupos en función de la tarea realizada. En primer lugar se incorporan los conjuntos de lectura: ZucCo 2.0 y el de Nieuwland et al. Posteriormente se introducen los conjuntos de escucha: SparrKULee y OpenNeuro ds007808. La adaptación comienza por lectura porque ofrece condiciones de experimentación relativamente controladas y permite realizar un primer entrenamiento con EEG relacionado con procesamiento lingüístico. Después se aproxima el dominio de entrenamiento a la tarea final mediante registros obtenidos durante la percepción auditiva del habla.

A pesar de las diferencias entre ellos, todos estos conjuntos se transforman a una interfaz común. Se conservan únicamente los canales EEG, junto con sus posiciones y una máscara para que el modelo tenga un único número de sensores de entrada, de forma que se enmascaran los sensores que no están presentes en un conjunto concreto. La señal se filtra inicialmente en su frecuencia de muestreo original y después se remuestrea a 50 Hz – al igual que en MEG-XL. A partir de cada grabación se extraen ventanas completas y no solapadas de 150 segundos. Los fragmentos finales que no alcanzan esta duración se descartan.

Durante esta etapa no se entrena utilizando ni las palabras, ni las transcripciones, ni las alineaciones lingüísticas como etiquetas. BioCodec transforma la señal en una secuencia discreta de códigos neuronales y el modelo aprende a reconstruir los códigos que han sido ocultados. De esta forma, los conjuntos de entrenamiento pueden combinarse aunque estén asociados a idiomas y paradigmas experimentales diferentes. Esto se hace para que el modelo aprenda regularidades temporales y espaciales de la señal EEG que puedan transferirse posteriormente a una tarea supervisada.

3.1 Selección de conjuntos de entrenamiento

MEG-XL se preentrena de forma autosupervisada con aproximadamente 300 horas de MEG procedentes de CamCAN, MOUS y SMN4Lang [23]. Estos conjuntos incluyen diferentes participantes, idiomas y tareas. Posteriormente, el modelo se ajusta y evalúa sobre conjuntos de escucha continua, como MEG-MASC, Armeni et al. y LibriBrain [17, 3, 30], tal como se resume en la Tabla 3.1.

Dataset	Tipo	Tarea	Idioma	Sujetos	Sensores	Duración	Uso en MEG-XL
CamCAN	MEG	Reposo y tarea sensoriomotora	No aplica	~700	306	~160 h	Preentrenamiento
MOUS	MEG	Escucha de oraciones	Neerlandés	104	275	~81 h	Preentrenamiento
SMN4Lang	MEG	Escucha de habla natural	Mandarín	12	306	~72 h	Preentrenamiento
MEG-MASC	MEG	Escucha de historias	Inglés	27	208	54 h	Ajuste y evaluación
Armeni et al.	MEG	Escucha de audiolibros	Inglés	3	269	30 h	Ajuste y evaluación
LibriBrain	MEG	Escucha de audiolibros	Inglés	1	306	52,32 h	Ajuste y evaluación

Tabla 3.1: Conjuntos de datos utilizados para el preentrenamiento y la evaluación de MEG-XL.

Para adaptar este procedimiento a EEG se buscaron conjuntos de lectura o escucha con señal suficientemente continua para extraer ventanas de 150 segundos. Se descartaron datasets formados únicamente por palabras o frases aisladas, aquellos que no proporcionaban la señal EEG completa y las tareas de producción oral, debido a la posible presencia de artefactos musculares. Se vio la necesidad de incluir datasets de lectura debido a la falta de conjuntos de escucha continua con un número suficiente de horas de entrenamiento. También se revisó la lateralidad de los participantes, priorizando sujetos diestros cuando esta información estaba disponible. Finalmente, se seleccionaron ZuCo 2.0 y Nieuwland et al. para lectura, y SparrKULee y OpenNeuro ds007808 para escucha. OpenNeuro ds004408 se mantiene separado de esta fase y se utiliza únicamente en el ajuste supervisado.

3.2 Datasets de entrenamiento

3.2.1. Datasets de lectura

ZuCo 2.0

ZuCO 2.0 es un conjunto de EEG y seguimiento ocular simultáneo registrado durante la lectura de frases en inglés [19]. Participaron 18 personas, que leyeron un total de 739 frases. De estas, 349 pertenecen a una tarea de lectura natural y 390 a una tarea de anotación en la que los participantes debían buscar relaciones semánticas concretas.

La señal se adquirió mediante un sistema de 128 electrodos a 500 Hz. Tras eliminar los canales utilizados para registrar actividad ocular, facial y del cuello, el conjunto proporciona 105 canales EEG. La adquisición simultánea de la mirada permite conocer qué palabra estaba observando el participante y durante cuánto tiempo. Esto resulta especialmente importante en lectura natural, porque las palabras no se muestran durante intervalos fijos, ya que cada persona puede detenerse, saltar una palabra o volver a una parte anterior de la frase.

En este trabajo se utiliza únicamente la tarea de lectura natural, denominada NR. La tarea específica de anotación se descarta porque introduce una búsqueda semántica explícita que modifica el proceso normal de lectura. La copia preprocesada empleada contiene aproximadamente 11.1 horas de señal NR.

La separación entre entrenamiento y validación se realiza por participante. Un 15 % de los sujetos se reserva de forma determinista para validación, utilizando una semilla fija. De esta manera se evita que segmentos de una misma persona aparezcan en ambos subconjuntos.

Nieuwland et al.

El conjunto que proponen Nieuwland et al. procede de un estudio de replicación a gran escala sobre predicción lingüística durante la lectura [28]. El experimento fue realizado de forma coordinada en nueve laboratorios y reunió datos válidos de 334 participantes. Esta distribución multicéntrica convierte al conjunto en uno de los registros EEG de lectura con mayor número de sujetos disponibles públicamente.

Los participantes de este estudio leían frases en inglés presentadas palabra por palabra. El experimento principal, denominado *DeLong*, estudiaba cómo la probabilidad de aparición de una palabra afectaba a la respuesta N400. Cada contexto conducía a sustantivos con distintos grados de predictibilidad y estaba precedido por el artículo correspondiente. El conjunto también incluye una tarea de control formada por frases más breves.

A diferencia de la lectura libre de ZuCo, la presentación visual estaba temporizada. Generalmente cada palabra se mostraba durante 200 ms y era seguida por un intervalo vacío de 300 ms. Esta presentación mantiene una velocidad de dos palabras por segundo y proporciona una referencia temporal común entre participantes.

Por otro lado, al tratarse de un estudio realizado en varios laboratorios, el número de canales, la frecuencia de muestreo y el equipo utilizado no son idénticos en todos los registros. El análisis ERP original redujo los datos a un conjunto común de electrodos para facilitar la comparación entre centros. En este trabajo no se reproduce esa reducción orientada al análisis de la N400. En su lugar se conservan los canales identificados como EEG y se utiliza una máscara de sensores para representar los distintos montajes dentro del mismo modelo.

Se emplean ambas tareas existentes. Las grabaciones se procesan como señal continua, sin proporcionar al modelo la identidad de las palabras ni su probabilidad de cierre. En conjunto, el estudio original aporta alrededor de 170 horas de EEG, aunque la cantidad efectiva utilizable depende de los registros que se encuentran disponibles en un formato compatible.

En este caso la validación vuelve a realizarse por participante. Se reserva un 10 % de los sujetos mediante una división determinista. Esto resulta especialmente importante en un conjunto multicéntrico, ya que obliga al modelo a enfrentarse durante la validación a personas y registros que no ha observado previamente.

3.2.2. Datasets de escucha

SparrKULee

SparrKULee es el primer dataset de escucha continua en el entrenamiento, se trata de un repositorio de respuestas EEG evocadas por habla creado en KU Leuven [1]. Contiene datos de 85 participantes jóvenes, con audición normal y neerlandés o flamenco como

lengua materna. Cada participante escuchó entre 90 y 150 minutos de habla natural, distribuidos en varios bloques de aproximadamente 15 minutos.

La adquisición se realizó con 64 canales EEG mediante un sistema BioSemi ActiveTwo. El conjunto completo reúne alrededor de 168 horas de señal. La mayor parte corresponde a narraciones sin ruido, aunque también algún fragmento de habla presentada en condiciones de ruido. Esta combinación se diseñó para estudiar el seguimiento cortical del habla y para entrenar modelos de codificación, decodificación y correspondencia entre EEG y audio.

En el entrenamiento se selecciona solo la tarea *listeningActive*. Los registros se procesan como secuencias continuas y se transforman a ventanas de 150 segundos. No se utilizan los atributos acústicos calculados por los autores ni las etiquetas de correspondencia entre segmentos.

Para la validación se reservan cinco participantes completos. Esta partición mantiene separados los sujetos de entrenamiento y permite comprobar la capacidad de generalización dentro de un sistema de adquisición homogéneo.

JapanEEG (OpenNeuro ds007808)

OpenNeuro ds007808, también denominado JapanEEG, es un conjunto multimodal de gran escala orientado al estudio del habla [34]. Incluye EEG, electromiografía facial y audio sincronizados de tres hablantes nativos de japonés. Los datos se registraron durante varios meses y mediante tres sistemas de adquisición diferentes, con configuraciones comprendidas entre 62 y 128 canales EEG.

El conjunto al completo supera las 1000 horas pero está dominado por una tarea de producción oral de vocabulario abierto. Por suerte, también contiene tareas de escucha y habla encubierta. Tiene una alta profundidad por participante, lo que permite estudiar variaciones entre sesiones, días y dispositivos que no aparecen en conjuntos más breves.

En este trabajo no se utiliza la tarea de producción oral *speechopen* pese a que representa la mayor parte del conjunto, ya que introduce actividad muscular facial y articular. Además, esta tarea se aleja del objetivo de decodificar palabras percibidas durante la escucha.

De este conjunto se seleccionan las tareas *listening* y *listeningcovert*. La primera contiene aproximadamente 33,8 horas de grabaciones de escucha. La segunda contiene cerca de 167 horas de registros en los que se alternan periodos de escucha y repetición mental. En estos registros se conserva la grabación completa como contexto, pero únicamente los intervalos etiquetados como escucha pueden seleccionarse como objetivo de reconstrucción. Los periodos de habla encubierta ayudan a mantener la continuidad temporal, pero no contribuyen directamente a la pérdida aplicada sobre los tokens enmascarados.

Esta decisión se tomó para aprovechar una parte considerable de las sesiones sin confundir percepción auditiva y producción imaginada. Al mismo tiempo, introduce un conjunto profundo y longitudinal que complementa el mayor número de sujetos de SparrKULee. Las particiones de validación se realizan mediante sesiones completas, de modo que una misma sesión no se divide entre entrenamiento y validación.

3.3 Dataset de fine-tuning

3.3.1. OpenNeuro ds004408

Se ha utilizado OpenNeuro ds004408 como dataset de *fine-tuning*. Este conjunto no se incorpora al entrenamiento autosupervisado continuo, sino que se reserva para la etapa supervisada de clasificación de palabras. De esta manera, el modelo se evalúa sobre registros que no han contribuido previamente a la reconstrucción de códigos neuronales y se evita mezclar datos de preentrenamiento y evaluación final.

OpenNeuro ds004408 contiene respuestas EEG de 19 participantes durante la escucha de habla narrativa continua en inglés. Los registros se adquirieron con 128 canales y se distribuyen en bloques de aproximadamente tres minutos, hasta reunir alrededor de 20,6 horas de señal. El conjunto fue utilizado originalmente para estudiar el seguimiento cortical de información fonética y el procesamiento semántico durante la comprensión de habla natural [13, 7]. Por ello resulta adecuado como conjunto final: comparte el dominio auditivo del objetivo experimental y, al mismo tiempo, cuenta con alineaciones temporales palabra a palabra que permiten formular una tarea supervisada.

En esta fase el dataset se procesa en formato *word-aligned*. Para cada palabra del audiolibro se extrae una ventana EEG de tres segundos alrededor de su inicio temporal, desde 0,5 segundos antes hasta 2,5 segundos después. El tramo previo permite estimar una línea base y conserva el contexto inmediato anterior, mientras que el tramo posterior recoge la respuesta asociada a la percepción y procesamiento de la palabra. Después de la corrección de línea base, la normalización robusta y el recorte de valores extremos, se agrupan 50 palabras consecutivas para formar entradas de 150 segundos. Así se mantiene la longitud temporal utilizada durante el entrenamiento, pero cada subventana queda asociada a una palabra conocida.

Las palabras se representan mediante *embeddings* lingüísticos de T5. El codificador neuronal produce una representación para cada ventana EEG y una proyección aprende a situarla cerca del *embedding* de la palabra correspondiente. El ajuste se realiza con una pérdida contrastiva, que acerca las parejas EEG–palabra correctas y separa las combinaciones incorrectas dentro del lote. Durante la evaluación se plantea una tarea de recuperación: dada una representación EEG alineada con una palabra, se ordenan los candidatos del vocabulario según su similitud y se comprueba si la palabra verdadera aparece entre las primeras posiciones.

La separación de ds004408 respecto al entrenamiento continuo también facilita la comparación con trabajos previos. En particular, en d’Ascoli et al. utilizan este conjunto dentro de una arquitectura de clasificación contextual de palabras y establecen métricas de recuperación sobre representaciones lingüísticas [9]. Esto permite comparar la adaptación propuesta no solo frente a una inicialización desde cero, sino también frente a referencias publicadas que trabajan sobre el mismo tipo de señal y tarea.

De esta forma, ds004408 cumple 2 funciones: actúa como conjunto supervisado para especializar el modelo en recuperación de palabras y proporciona un punto de comparación cuantitativa con el estado del arte. La decisión de reservarlo exclusivamente para *fine-tuning* hace que cualquier mejora pueda atribuirse a la transferencia desde las etapas previas y no a una exposición autosupervisada al mismo registro.

3.4 Tabla resumen

La Tabla 3.2 resume las principales características de los conjuntos descritos y la función que desempeña cada uno dentro del trabajo.

Dataset	Tipo	Tarea	Idioma	Sujetos	Sensores	Duración	Uso
ZuCo 2.0	EEG	Lectura natural	Inglés	18	105	11,1 h NR	Training
Nieuwland et al.	EEG	Lectura temporizada	Inglés	334	≥ 32	~ 170 h	Training
SparrKULee	EEG	Escucha	Neerlandés	85	64	168 h	Training
OpenNeuro ds007808	EEG	Escucha	Japonés	3	62–128	33,8 h (+167,0 h)	Training
OpenNeuro ds004408	EEG	Escucha	Inglés	19	128	20,6 h	Fine-tuning

Tabla 3.2: Resumen de los conjuntos de datos utilizados y su función dentro del proceso experimental. En ds007808, las horas de *listeningcovert* corresponden a grabaciones completas utilizadas como contexto y no a 167 horas de objetivos exclusivamente auditivos.

CAPÍTULO 4

Adaptación de MEG-XL a “EEG-XL”

4.1 Descripción general de la propuesta

Como se ha ido comentando a lo largo de los anteriores capítulos, la propuesta de este trabajo consiste en adaptar MEG-XL a registros EEG. La idea es mantener, dentro de lo que sea posible, aquello que hace valioso al modelo original, como por ejemplo el aprendizaje autosupervisado con contexto largo. MEG-XL no se limita a procesar ventanas breves alineadas con palabras, sino que aprende representaciones a partir de fragmentos continuos de dos minutos y medio. Esta propiedad resulta especialmente interesante para EEG, donde la señal es más ruidosa y la información lingüística puede aparecer distribuida en patrones débiles a lo largo del tiempo.

Esta adaptación se puede entender como un cambio de dominio. El modelo de partida fue entrenado con MEG, utilizando sensores magnéticos, geometrías específicas y una relación señal-ruido distinta. En EEG cambian la magnitud física, la referencia, la disposición de los sensores, el número de canales y los artefactos más frecuentes. Por tanto, es necesario construir una interfaz común que permita representar diferentes montajes EEG dentro de la misma arquitectura.

El entrenamiento final lanzado en este trabajo corresponde a un preentrenamiento continuo en dos etapas. Primero se utilizan datasets de lectura y después datasets de escucha. La etapa de lectura sirve como una adaptación inicial a EEG lingüístico en condiciones más controladas. La etapa de escucha aproxima el modelo al dominio final, que es la clasificación de palabras durante percepción auditiva continua.

Además, el experimento compara dos inicializaciones. En una de ellas el modelo parte del modelo que presenta MEG-XL. En la otra, la misma arquitectura se inicializa desde cero. Ambas siguen exactamente el mismo orden, lectura seguida de escucha, de modo que la comparación permite estudiar si el preentrenamiento con MEG aporta algún tipo de ventaja al pasar a EEG o si las diferencias entre modalidades impiden aprovecharlo.

La propuesta final se puede resumir en la imitación de cuatro decisiones:

- utilizar ventanas continuas de 150 segundos, como en MEG-XL;
- filtrar la señal entre 0,1 y 40 Hz y remuestrearla a 50 Hz;
- tokenizar cada canal con BioCodec y entrenar mediante predicción de tokens enmascarados;
- realizar el entrenamiento en dos fases, primero lectura y después escucha, comparando inicialización desde MEG-XL e inicialización aleatoria.

De esta forma, la parte supervisada de clasificación de palabras queda separada del preentrenamiento, como sucede con MEG-XL. Los cinco datasets descritos en el capítulo anterior se utilizan para intentar aprender una representación “general” de EEG. Posteriormente, Weissbart et al. permite ajustar esa representación a una tarea *word-aligned* concreta, con ventanas asociadas al inicio de cada palabra y evaluación mediante recuperación de embeddings lingüísticos.

4.2 Preprocesamiento del EEG

4.2.1. Preprocesado de la señal

Todos los datasets de entrenamiento se transforman a una frecuencia de muestreo común de 50 Hz tal y como lo hace MEG-XL. Esta elección reduce el coste computacional de las ventanas largas. Un segmento de 150 segundos contiene 7500 muestras por canal antes de la tokenización, por lo que aumentar la frecuencia de muestreo incrementaría de forma directa la memoria necesaria y el número de tokens que debe procesar el Transformer.

El entrenamiento realizado utiliza un filtrado paso banda de 0,1–40 Hz. La señal se filtra en su frecuencia de muestreo original y después se remuestrea a 50 Hz. Esta decisión conserva la lógica del preprocesamiento original de MEG-XL: primero se trabaja sobre la señal disponible en origen y posteriormente se reduce la frecuencia para construir una entrada homogénea. En la práctica, el remuestreo aplica el filtrado antialiasing necesario para obtener una señal compatible con la frecuencia final. Además, se tiene en cuenta que esta combinación rompe la frecuencia de Nyquist, pero en MEG-XL [?] se pueden ver los experimentos que hicieron que reportaban peores resultados con frecuencias de muestreo más altas. Por tanto, se decidió mantener la frecuencia de 50 Hz para poder comparar los resultados con los obtenidos en MEG-XL.

Después del filtrado y el remuestreo, cada grabación se divide en ventanas completas de 150 segundos. Para montar estas ventanas se utilizan segmentos continuos y no solapados dentro de cada registro. Los fragmentos finales que no alcanzan la duración requerida se descartan. Esta decisión evita introducir relleno artificial, repetir muestras para completar una ventana o unir partes de la señal que no son contiguas, lo que podría introducir artefactos y sesgos en el entrenamiento.

A partir de cada ventana de 150 segundos, se subdivide la señal en bloques de tres segundos. Esta subdivisión mantiene la escala temporal utilizada por MEG-XL y coincide con la duración de las ventanas que más tarde se utilizan en clasificación de palabras. Durante el preentrenamiento continuo, esos bloques no se asocian a palabras concretas; funcionan como unidades temporales sobre las que se puede aplicar el enmascaramiento.

La normalización se aplica para reducir diferencias de escala entre canales, sesiones y datasets. Este paso es de vital importancia en EEG porque cada conjunto puede haber sido registrado con amplificadores, referencias y montajes distintos. La normalización no elimina por completo estas diferencias, pero evita que el modelo dependa de magnitudes absolutas que no son comparables entre datasets.

Siguiendo el ejemplo de MEG-XL, se ha creado una interfaz común para cargar los datasets. Cada ejemplo contiene la señal EEG, las posiciones de los sensores y una máscara que indica qué canales son reales. Cuando un conjunto tiene menos sensores que otro, no se fuerza una interpolación espacial previa; se representa dentro de una dimensión común y se enmascaran los canales ausentes. Así, el modelo puede entrenar con diferentes montajes sin confundir sensores inexistentes con señales de valor cero.

4.2.2. Alineamiento con las palabras

El entrenamiento autosupervisado final no utiliza palabras, transcripciones ni alineaciones lingüísticas como etiquetas. Durante las etapas de lectura y escucha, el modelo recibe EEG continuo y aprende a reconstruir códigos neuronales ocultos. Por tanto, pueden combinarse datasets con idiomas y paradigmas diferentes sin construir un vocabulario común.

En los conjuntos de lectura, las anotaciones de presentación visual o fijación sirven para seleccionar tareas relacionadas con procesamiento lingüístico, pero no se utilizan como objetivo de entrenamiento. En ZuCo se emplea la tarea de lectura natural, y en el conjunto de Nieuwland et al. las tareas *delong* y *control*. En los conjuntos de escucha, se seleccionan tareas de percepción auditiva continua. En OpenNeuro ds007808, los registros *listeningcovert* se tratan con cuidado: la grabación completa puede proporcionar contexto, pero solo los intervalos etiquetados como escucha son candidatos para ser enmascarados y reconstruidos.

El alineamiento palabra a palabra aparece después, en la etapa de *fine-tuning* con OpenNeuro ds004408. En ese caso sí se extraen ventanas de tres segundos alrededor del inicio de cada palabra y se agrupan 50 palabras consecutivas para formar una entrada de 150 segundos. De esta forma primero el modelo aprende regularidades generales de EEG continuo y después ya se especializa en recuperación de palabras.

4.3 Adaptación de la arquitectura MEG-XL

4.3.1. Componentes conservados

La adaptación final mantiene la arquitectura principal de MEG-XL. La señal se tokeniza con BioCodec, que transforma cada canal en una secuencia discreta de códigos mediante cuantización vectorial residual. En la configuración utilizada, BioCodec emplea un vocabulario de 256 códigos, seis cuantizadores y un factor de reducción temporal de 12. De esta forma, los 7500 puntos temporales de una ventana de 150 segundos a 50 Hz se convierten en una secuencia de tokens más corta, manejable por el Transformer.

Sobre esos tokens se aplica el Transformer con una combinación de 2 tipos de atención que se llama atención cruzada *criss-cross*. La atención temporal permite relacionar momentos dentro de un mismo sensor, mientras que la atención espacial combina información entre sensores para un mismo instante. Esta factorización conserva la idea original de MEG-XL: modelar dependencias largas sin construir una atención completa sobre todos los pares canal-tiempo.

También se conserva el objetivo autosupervisado. El modelo oculta bloques temporales y debe predecir los códigos de BioCodec correspondientes a esas posiciones. La *loss* es una entropía cruzada sobre los códigos discretos de los cuantizadores. En el entrenamiento se enmascaran subsegmentos de tres segundos, de forma que el modelo no puede resolver la tarea únicamente interpolando muestras vecinas inmediatas y fuerza al Transformer a aprender patrones más amplios de la señal.

Por tanto, la contribución de la adaptación está en hacer que la misma arquitectura pueda recibir EEG heterogéneo y en definir un curriculum de entrenamiento adecuado para pasar de lectura a escucha. La arquitectura, el tokenizer y el objetivo autosupervisado se mantienen lo más cerca posible de MEG-XL, mientras que los cambios se concentran en la entrada EEG, las máscaras de sensores, la selección de datasets y el entrenamiento por etapas.

4.3.2. Cambios para trabajar con canales EEG

MEG-XL fue diseñado para trabajar con magnetómetros y gradiómetros. En EEG solo existe un tipo de sensor dentro del experimento, pero los montajes varían mucho entre datasets. Por ello se introduce el tipo de sensor EEG dentro del espacio de tipos ya utilizado por la arquitectura. La configuración final mantiene tres tipos posibles: gradiómetro, magnetómetro y EEG. En los datos de este trabajo todos los canales reales pertenecen al tipo EEG, pero conservar los otros tipos permite cargar parcialmente los pesos de MEG-XL sin rediseñar el modelo.

La posición de cada electrodo se utiliza como información espacial al no tener el índice de un canal el mismo significado en todos los conjuntos. Un canal situado en una región frontal no debería tratarse como equivalente a otro canal occipital solo porque ocupa la misma posición en una matriz. Al proporcionar coordenadas y máscaras de sensores, el modelo puede aprender relaciones espaciales en función de la geometría real disponible en cada registro.

Formalmente, si el canal c tiene coordenadas normalizadas $\mathbf{p}_c = (x_c, y_c, z_c) \in \mathbb{R}^3$ y tipo de sensor $s_c \in \{0, 1, 2\}$, con 0 para gradiómetro, 1 para magnetómetro y 2 para EEG, la información espacial se introduce mediante un *embedding* Fourier gaussiano:

$$\boldsymbol{\phi}(\mathbf{p}_c) = [\sin(2\pi\mathbf{p}_c\mathbf{B}), \cos(2\pi\mathbf{p}_c\mathbf{B})], \quad \mathbf{B}_{ij} \sim \mathcal{N}(0, \sigma^2), \quad (4.1)$$

donde $\mathbf{B} \in \mathbb{R}^{3 \times d_F/2}$ es una matriz de frecuencias fija. Este vector se proyecta a la dimensión latente del modelo:

$$\mathbf{e}_c^{\text{pos}} = \mathbf{W}_{\text{pos}}\boldsymbol{\phi}(\mathbf{p}_c) + \mathbf{b}_{\text{pos}}. \quad (4.2)$$

El tipo de sensor se representa mediante una tabla aprendida $\mathbf{E}_{\text{type}} \in \mathbb{R}^{3 \times d}$:

$$\mathbf{e}_c^{\text{type}} = \mathbf{E}_{\text{type}}[s_c]. \quad (4.3)$$

Por tanto, para el token temporal τ del canal c , el vector de entrada al Transformer queda:

$$\mathbf{h}_{c,\tau}^{(0)} = \mathbf{e}_{c,\tau}^{\text{tok}} + \mathbf{e}_c^{\text{pos}} + \mathbf{e}_c^{\text{type}}. \quad (4.4)$$

En los registros EEG de este trabajo se usa $s_c = 2$ para todos los canales reales. La posición distingue electrodos dentro de un mismo montaje y el tipo de sensor permite mantener la compatibilidad con los pesos de MEG-XL sin confundir la modalidad física de la señal.

Otra diferencia con respecto a MEG-XL es el tamaño de nuestro modelo debido al número de canales máximo de los datasets. Nuestros datos de EEG contienen montajes de 64, 105, 128 o configuraciones variables según el laboratorio y la sesión. La dimensión máxima de canales se infiere a partir de los datasets disponibles y a cada uno se le aplica una máscara. Esta máscara se aplica tanto durante el procesamiento como en el cálculo de la pérdida, evitando que los canales añadidos para igualar dimensiones modifiquen canales entrenados.

Algunos experimentos utilizan como base el modelo preentrenado con MEG de MEG-XL. En ese caso, el modelo se carga en la nueva arquitectura de forma parcial. Los pesos compatibles, como los del Transformer y gran parte de las proyecciones internas, pueden reutilizarse. Los componentes que dependen de la nueva configuración EEG o que dejan

Tabla 4.1: Resumen de la arquitectura y número de parámetros del modelo EEG.

N.	Componente	Tipo	Parámetros
0	tokenizer	BioCodecTokenizerAdapter	3,2 M
1	rvq_projector	Linear	49,7 K
2	position_fourier_emb	GaussianFourierEmb3D	375
3	position_projector	Linear	128 K
4	orientation_fourier_emb	GaussianFourierEmb3D	375
5	orientation_projector	Linear	128 K
6	sensor_type_layer	Embedding	1,5 K
7	criss_cross_transformer	SpatialTemporalEncoder	21,0 M
8	output_head	Linear	787 K
Parámetros entrenables			22,1 M
Parámetros no entrenables			3,2 M
Parámetros totales			25,3 M

de encajar exactamente se inicializan de nuevo. De esta forma, la carga parcial permite estudiar la transferencia de MEG a EEG sin forzar una equivalencia falsa entre sensores de diferentes tareas.

4.3.3. Tokenización de la señal

Durante el desarrollo se contemplaron otros tokenizadores, como BrainOmni o BrainTokenizer, porque están diseñados para representar bioseñales heterogéneas y podrían ser adecuados para combinar modalidades. Sin embargo, finalmente el entrenamiento utiliza BioCodec. Así se mantiene la compatibilidad con MEG-XL y se reduce el número de cambios simultáneos: si se cambiara a la vez la modalidad, el tokenizer y la arquitectura, sería más difícil interpretar el efecto de la transferencia. Por otro lado, es un tokenizador entrenado sobre EEG, por lo que, teóricamente, debería funcionar mejor con nuestro conjunto de datos que con el de MEG-XL.

BioCodec se aplica canal a canal. Cada canal EEG se convierte en una secuencia de códigos discretos y el Transformer aprende sobre esos códigos junto con la información de posición y tipo de sensor. El uso de seis cuantizadores permite representar la señal mediante varios niveles discretos. La salida del modelo predice, para cada posición enmascarada, el código correspondiente en cada cuantizador.

4.3.4. Modelado temporal y espacial

La arquitectura final trabaja con segmentos largos de 150 segundos. Esta escala es mucho mayor que la utilizada por la mayoría de modelos EEG centrados en ventanas de pocos segundos. El objetivo es que las capas del Transformer aprendan tanto patrones locales como dependencias más amplias relacionadas con el estado de la grabación, la continuidad del estímulo y la dinámica temporal del procesamiento lingüístico.

La atención *criss-cross* separa explícitamente dos dimensiones. En la dimensión temporal, el modelo analiza cómo evoluciona la señal dentro de un sensor. En la dimensión espacial, integra información entre sensores manteniendo el mismo instante tokenizado. Esta separación reduce el coste respecto a una atención completa y se adapta de forma natural a la representación canal-tiempo del EEG.

En los registros *listeningcovert* de ds007808 se añade una restricción adicional mediante una máscara de objetivo. El contexto puede incluir toda la grabación, pero la pérdida

solo se aplica sobre intervalos de escucha. Esto evita que el modelo sea entrenado para reconstruir como objetivo principal periodos de habla encubierta, que no corresponden directamente a la percepción auditiva que se quiere transferir a ds004408.

4.4 Entrenamiento del modelo

4.4.1. Preentrenamiento autosupervisado

Cada entrenamiento ejecuta dos fases consecutivas:

1. entrenamiento continuo con datasets de lectura;
2. entrenamiento continuo con datasets de escucha, inicializado desde el mejor checkpoint de la fase de lectura correspondiente.

La fase de lectura utiliza Nieuwland et al. y ZuCo 2.0 en lectura natural. La fase de escucha utiliza SparrKULEE y JapanEEG. La validación respeta separaciones por sujeto o por sesión según el dataset, como se describió en el capítulo anterior.

El orden de lectura → escucha se escogió para que los datasets de lectura proporcionen una primera adaptación a EEG lingüístico con estímulos visuales y condiciones relativamente controladas. Después, los datasets de escucha ajustan la representación al dominio auditivo continuo, que es el más próximo a la evaluación final con ds004408. El checkpoint producido por lectura se pasa explícitamente a la etapa de escucha, por lo que no se reutilizan checkpoints de experimentos anteriores de escucha aislada.

De esta forma el entrenamiento del modelo tiene la siguiente configuración: BioCodec, frecuencia final de 50 Hz, banda 0,1–40 Hz, ventanas de 150 segundos, batch size 4 en lectura y escucha salvo que se sobrescriba por variable de entorno, validación cada 500 pasos y guardado periódico de checkpoints. El entrenamiento se ejecuta con una GPU por inicialización, de forma que las dos condiciones se lanzan al mismo tiempo pero no comparten pesos entre sí.

En MEG-XL se realizó el entrenamiento con un batch size de 1, pero el hecho de tener 5M de parámetros menos y la mitad de canales permite aumentar el batch size a 4 sin superar la memoria de una GPU A100 de 40 GB. Así se reduce la varianza del gradiente y acelera la convergencia, aunque también puede afectar a la generalización. Por ello, se mantiene la misma configuración para lectura y escucha, de modo que cualquier efecto del batch size se aplica por igual a ambas fases.

4.4.2. Clasificación contextual de palabras

El modelo de MEG-XL destaca por tener pocos parámetros entrenables para poder adaptarse a tareas supervisadas concretas. En este trabajo se mantiene la misma filosofía: el preentrenamiento autosupervisado aprende representaciones generales de EEG y la evaluación final se realiza mediante una tarea supervisada de clasificación contextual de palabras.

La clasificación contextual de palabras no forma parte del preentrenamiento autosupervisado continuo, sino que constituye la tarea supervisada utilizada para evaluar la calidad de las representaciones aprendidas. Una vez completadas las etapas de lectura y escucha, los checkpoints resultantes se emplean para inicializar el *fine-tuning* sobre OpenNeuro ds004408. Este conjunto se reserva para esta fase y no se incorpora al con-

junto de datos previo, evitando que el modelo haya observado previamente durante el preentrenamiento los registros utilizados en la evaluación final.

Las anotaciones temporales de ds004408 se obtienen de los niveles de palabras incluidos en los ficheros *TextGrid*, descartando los niveles correspondientes a fonemas. Para cada palabra se extrae una ventana EEG de tres segundos, comprendida entre 0,5 segundos antes de su inicio y 2,5 segundos después. Posteriormente, se concatenan las ventanas correspondientes a 50 palabras consecutivas, produciendo una entrada de 150 segundos. Por tanto, la dimensión temporal coincide con la empleada durante el preentrenamiento, aunque en este caso no se trata necesariamente de 150 segundos continuos de la grabación original, sino de una secuencia estructurada de ventanas alineadas con palabras.

El modelo procesa conjuntamente las 50 ventanas y genera una representación para cada palabra. Sobre las características producidas por el Transformer se aplica una cabeza de proyección que transforma cada representación cerebral en un vector de 1024 dimensiones. Como objetivo lingüístico se utilizan embeddings extraídos de la capa intermedia 12 de *T5-large*. El aprendizaje se realiza mediante una pérdida contrastiva de tipo SigLIP, que aproxima la representación predicha al embedding de la palabra correcta y la separa de los embeddings correspondientes al resto de palabras presentes en el lote.

Durante la evaluación, cada embedding cerebral predicho se compara mediante similitud coseno con los embeddings lingüísticos de un conjunto de recuperación. Se consideran vocabularios formados por las 50 y las 250 palabras más frecuentes y se calcula la precisión *Top-10*, junto con su variante balanceada por palabra. Esta evaluación sigue la formulación de recuperación semántica utilizada en los trabajos de clasificación contextual de palabras, aunque los resultados solo pueden compararse directamente cuando coinciden el conjunto de candidatos, la partición de los datos y el protocolo de evaluación.

CAPÍTULO 5

Evaluación experimental

5.1 Configuración de los experimentos

5.1.1. Particiones de los datos

5.1.2. Hiperparámetros y métricas

5.2 Entrenamiento desde cero y transferencia desde MEG-XL

5.2.1. Inicialización desde cero y desde MEG-XL

5.3 Comparación de tokenizadores

5.4 Comparación de tareas

5.4.1. Lectura

5.4.2. Escucha

5.4.3. Lectura y escucha combinadas

5.5 Discusión de los resultados

5.5.1. Principales conclusiones experimentales

5.5.2. Limitaciones

CAPÍTULO 6

Conclusiones y trabajo futuro

6.1 Conclusiones

6.2 Cumplimiento de los objetivos

6.3 Líneas de trabajo futuro

Bibliografía

- [1] Bernd Accou, Lies Bollens, Marlies Gillis, Wendy Verheijen, Hugo Van hamme, and Tom Francart. SparrKULee: A speech-evoked auditory response repository from KU Leuven, containing the EEG of 85 participants. *Data*, 9(8):94, 2024.
- [2] Salwa Alzahrani, Haneen Banjar, and Rsha Mirza. Systematic review of EEG-based imagined speech classification methods. *Sensors*, 24(24):8168, 2024.
- [3] Kristijan Armeni, Umut Güçlü, Marcel A. J. van Gerven, and Jan-Mathijs Schoffelen. A 10-hour within-participant magnetoencephalography narrative dataset to test models of language comprehension. *Scientific Data*, 9:278, 2022.
- [4] Konstantinos Avramidis, Tiantian Feng, Won Jeong, Joon Lee, Weizhong Cui, Richard M. Leahy, and Shrikanth Narayanan. Neural codecs as biosignal tokenizers, 2025.
- [5] Alexei Baevski, Yuhao Zhou, Abdelrahman Mohamed, and Michael Auli. wav2vec 2.0: A framework for self-supervised learning of speech representations. In *Advances in Neural Information Processing Systems*, volume 33, pages 12449–12460, 2020.
- [6] Elena Boto, Niall Holmes, James Leggett, Gillian Roberts, Vishal Shah, Sofie S. Meyer, Leonardo Duque Muñoz, Karen J. Mullinger, Tim M. Tierney, Sven Bestmann, Gareth R. Barnes, Richard Bowtell, and Matthew J. Brookes. Moving magnetoencephalography towards real-world applications with a wearable system. *Nature*, 555(7698):657–661, 2018.
- [7] Michael P. Broderick, Andrew J. Anderson, Giovanni M. Di Liberto, Michael J. Crosse, and Edmund C. Lalor. Electrophysiological correlates of semantic dissimilarity reflect the comprehension of natural, narrative speech. *Current Biology*, 28(5):803–809, 2018.
- [8] György Buzsáki and Andreas Draguhn. Neuronal oscillations in cortical networks. *Science*, 304(5679):1926–1929, 2004.
- [9] Stéphane d’Ascoli, Corentin Bel, Jérémy Rapin, Hubert J. Banville, Yohann Bencheit, Christophe Pallier, and Jean-Rémi King. Towards decoding individual words from non-invasive brain recordings. *Nature Communications*, 16:10521, 2025. Preprint originally released as arXiv:2412.17829.
- [10] Debadatta Dash, Paul Ferrari, and Jun Wang. Decoding imagined and spoken phrases from non-invasive neural (MEG) signals. *Frontiers in Neuroscience*, 14:290, 2020.
- [11] Alexandre Défossez, Charlotte Caucheteux, Jérémy Rapin, Ori Kabeli, and Jean-Rémi King. Decoding speech perception from non-invasive brain recordings. *Nature Machine Intelligence*, 5:1097–1107, 2023.

- [12] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019.
- [13] Giovanni M. Di Liberto, James A. O’Sullivan, and Edmund C. Lalor. Low-frequency cortical entrainment to speech reflects phoneme-level processing. *Current Biology*, 25(19):2457–2465, 2015.
- [14] Yiqun Duan, Jinzhao Zhou, Zhen Wang, Yu-Kai Wang, and Chin-Teng Lin. DeWave: Discrete encoding of EEG waves for EEG-to-text translation. In *Advances in Neural Information Processing Systems*, volume 36, pages 9907–9918, 2023.
- [15] Andreas K. Engel and Pascal Fries. Beta-band oscillations—signalling the status quo? *Current Opinion in Neurobiology*, 20(2):156–165, 2010.
- [16] Joachim Gross, Sylvain Baillet, Gareth R. Barnes, Richard N. Henson, Arjan Hillebrand, Ole Jensen, Karim Jerbi, Vladimir Litvak, Burkhard Maess, Robert Oostenveld, Lauri Parkkonen, Jason R. Taylor, Virginie van Wassenhove, Michael Wibral, and Jan-Mathijs Schoffelen. Good practice for conducting and reporting MEG research. *NeuroImage*, 65:349–363, 2013.
- [17] Laura Gwilliams, Graham Flick, Alec Marantz, Liina Pylkkänen, David Poeppel, and Jean-Rémi King. Introducing MEG-MASC: A high-quality magnetoencephalography dataset for evaluating natural speech processing. *Scientific Data*, 10:862, 2023.
- [18] Matti S. Hämäläinen, Riitta Hari, Risto J. Ilmoniemi, Jukka Knuutila, and Olli V. Lounasmaa. Magnetoencephalography—theory, instrumentation, and applications to noninvasive studies of the working human brain. *Reviews of Modern Physics*, 65(2):413–497, 1993.
- [19] Nora Hollenstein, Marius Troendle, Ce Zhang, and Nicolas Langer. ZuCo 2.0: A dataset of physiological recordings during natural reading and annotation. In *Proceedings of the Twelfth Language Resources and Evaluation Conference*, pages 138–146, Marseille, France, 2020. European Language Resources Association.
- [20] Herbert H. Jasper. The ten-twenty electrode system of the international federation. *Electroencephalography and Clinical Neurophysiology*, 10:371–375, 1958.
- [21] Dulhan Jayalath, Gilad Landau, and Oiwi Parker Jones. Unlocking non-invasive brain-to-text, 2025.
- [22] Dulhan Jayalath, Gilad Landau, Brendan Shillingford, Mark Woolrich, and Oiwi Parker Jones. The brain’s bitter lesson: Scaling speech decoding with self-supervised learning. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 27005–27020. PMLR, 2025.
- [23] Dulhan Jayalath and Oiwi Parker Jones. MEG-XL: Data-efficient brain-to-text via long-context pre-training, 2026.
- [24] Weibang Jiang, Liming Zhao, and Bao-Liang Lu. Large brain model for learning generic representations with tremendous EEG data in BCI. In *The Twelfth International Conference on Learning Representations*, 2024.
- [25] Hyejeong Jo, Yiqian Yang, Juhyeok Han, Yiqun Duan, Hui Xiong, and Won Hee Lee. Are EEG-to-text models working?, 2024.

- [26] Wolfgang Klimesch. EEG alpha and theta oscillations reflect cognitive and memory performance: A review and analysis. *Brain Research Reviews*, 29(2–3):169–195, 1999.
- [27] Elon Musk and Neuralink. An integrated brain-machine interface platform with thousands of channels. *Journal of Medical Internet Research*, 21(10):e16194, 2019.
- [28] Mante S. Nieuwland et al. Large-scale replication study reveals a limit on probabilistic prediction in language comprehension. *eLife*, 7:e33468, 2018.
- [29] Robert Oostenveld and Peter Praamstra. The five percent electrode system for high-resolution EEG and ERP measurements. *Clinical Neurophysiology*, 112(4):713–719, 2001.
- [30] Miran Özdogan, Gilad Landau, Gereon Elvers, Dulhan Jayalath, Pratik Somaiya, Francesco Mantegna, Mark Woolrich, and Oiwi Parker Jones. LibriBrain: Over 50 hours of within-subject MEG to improve speech decoding methods at scale. In *Advances in Neural Information Processing Systems: Datasets and Benchmarks Track*, 2025.
- [31] Jerrin Thomas Panachakel and Angarai Ganesan Ramakrishnan. Decoding covert speech from EEG—a comprehensive review. *Frontiers in Neuroscience*, 15:642251, 2021.
- [32] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020.
- [33] Luis Carlos Sarmiento, Sergio Villamizar, Omar López, Ana Claros Collazos, Jhon Sarmiento, and Jan Bacca Rodríguez. Recognition of EEG signals from imagined vowels using deep learning methods. *Sensors*, 21(19):6503, 2021.
- [34] Motoshige Sato, Ilya Horiguchi, Masakazu Inoue, Kenichi Tomeoka, Eri Hatakeyama, Yuya Kita, Atsushi Yamamoto, Ippei Fujisawa, and Shuntaro Sasai. A 1000-hour EEG–EMG–Audio dataset of japanese speech production, 2026. Dataset OpenNeuro ds007808.
- [35] Motoshige Sato, Kenichi Tomeoka, Ilya Horiguchi, Kai Arulkumaran, Ryota Kanai, and Shuntaro Sasai. Scaling law in neural data: Non-invasive speech decoding with 175 hours of EEG data, 2024.
- [36] Markus-Oliver Tamm, Yar Muhammad, and Naveed Muhammad. Classification of vowels from imagined speech with convolutional neural networks. *Computers*, 9(2):46, 2020.
- [37] Samu Taulu and Matti Kajola. Presentation of electromagnetic multichannel data: The signal space separation method. *Journal of Applied Physics*, 97(12):124905, 2005.
- [38] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [39] Guangyu Wang, Wenchao Liu, Yuhong He, Cong Xu, Lin Ma, and Haifeng Li. EEGPT: Pretrained transformer for universal and reliable representation of EEG signals. In *Advances in Neural Information Processing Systems*, volume 37, pages 39249–39280, 2024.

-
- [40] Jiquan Wang, Sha Zhao, Zhiling Luo, Yangxuan Zhou, Haiteng Jiang, Shijian Li, Tao Li, and Gang Pan. CBraMod: A criss-cross brain foundation model for EEG decoding. In *The Thirteenth International Conference on Learning Representations*, 2025.
 - [41] Zhenhailong Wang and Heng Ji. Open vocabulary electroencephalography-to-text decoding and zero-shot sentiment classification. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 5350–5358, 2022.
 - [42] Jonathan R. Wolpaw, Niels Birbaumer, Dennis J. McFarland, Gert Pfurtscheller, and Theresa M. Vaughan. Brain-computer interfaces for communication and control. *Clinical Neurophysiology*, 113(6):767–791, 2002.
 - [43] Qinfan Xiao, Ziyun Cui, Chi Zhang, Siqi Chen, Wen Wu, Andrew Thwaites, Alexandra Woolgar, Bowen Zhou, and Chao Zhang. BrainOmni: A brain foundation model for unified EEG and MEG signals. In *Advances in Neural Information Processing Systems*, 2025.
 - [44] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11975–11986, 2023.

APÉNDICE A

Configuració del sistema

???? ????????????? ????????????? ????????????? ????????????? ?????????????

A.1 Fase d'inicialització

???? ????????????? ????????????? ????????????? ????????????? ?????????????

A.2 Identificació de dispositius

???? ????????????? ????????????? ????????????? ????????????? ?????????????

APÉNDICE B

??? ?????????????? ????

???? ?????????????? ?????????????? ?????????????? ?????????????? ??????????????