



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Departamento de Sistemas Informáticos y Computación
Universidad Politécnica de Valencia

Transferencia de modelos MEG de contexto largo a EEG para clasificación de palabras en lectura natural

TRABAJO DE FIN DE MÁSTER

Máster Universitario en Inteligencia Artificial,
Reconocimiento de Formas e Imagen Digital

Autor: Ricardo Díaz Peris

Tutores: Vicent Juan Botti Navarro, Alfons Juan Císcar

Curso 2025-2026

Resum

La decodificación de palabras a partir de señales cerebrales no invasivas presenta importantes dificultades debidas al bajo nivel de señal útil, la variabilidad entre sujetos y las diferencias entre modalidades como MEG y EEG. En este trabajo se adapta el modelo MEG-XL, diseñado originalmente para el aprendizaje de representaciones de contexto largo en MEG, a un escenario de EEG durante lectura natural. La adaptación se centra en construir un pipeline reproducible para evaluar si las representaciones aprendidas en MEG pueden transferirse a EEG en tareas de clasificación de palabras. Para ello, se integra la arquitectura de MEG-XL con un nuevo adaptador diferentes datasets de EEG, que transforma los registros de este tipo de sensores y las anotaciones de lectura en segmentos alineados a palabras. El pipeline incorpora re-muestreo, normalización, extracción de ventanas temporales por palabra, máscaras de sensores y codificación explícita del tipo de sensor EEG. A partir de estos segmentos, el modelo obtiene representaciones neuronales contextualizadas mediante un Transformer con atención criss-cross y las compara con embeddings lingüísticos generados por T5 mediante una pérdida contrastiva. El objetivo principal es analizar la viabilidad técnica y experimental de trasladar modelos de contexto largo entrenados en MEG a datos EEG para comenzar a investigar una solución cerrada de brain-to-text que incluya EEG. Este enfoque permite estudiar las barreras prácticas de la transferencia entre modalidades, identificar los puntos críticos del preprocesamiento y sentar una base para futuros modelos multimodales M/EEG aplicados a decodificación de lenguaje natural.

Paraules clau: Descodificació neuronal; EEG; MEG; aprenentatge per transferència; lectura natural; classificació de paraules; models de context llarg; brain-to-text

Resumen

La descodificació de paraules a partir de senyals cerebrals no invasives presenta importants dificultats degudes al baix nivell de senyal útil, la variabilitat entre subjectes i les diferències entre modalitats com MEG i EEG. En este treball s'adapta el model MEG-XL, dissenyat originalment per a l'aprenentatge de representacions de context llarg en MEG, a un escenari d'EEG durant lectura natural. L'adaptació se centra a construir un pipeline reproduïble per a avaluar si les representacions apreses en MEG poden transferir-se a EEG en tasques de classificació de paraules. Per això, s'integra l'arquitectura de MEG-XL amb un nou adaptador per a diferents conjunts de dades d'EEG, que transforma els registres d'aquest tipus de sensors i les anotacions de lectura en segments alineats amb paraules. El pipeline incorpora remostratge, normalització, extracció de finestres temporals per paraula, màscares de sensors i codificació explícita del tipus de sensor EEG. A partir d'aquests segments, el model obté representacions neuronals contextualitzades mitjançant un Transformer amb atenció criss-cross i les compara amb embeddings lingüístics generats per T5 mitjançant una pèrdua contrastiva. L'objectiu principal és analitzar la viabilitat tècnica i experimental de traslladar models de context llarg entrenats en MEG a dades EEG per a començar a investigar una solució tancada de brain-to-text que incloga EEG. Este enfocament permet estudiar les barreres pràctiques de la transferència entre modalitats, identificar els punts crítics del preprocesament i assentar una base per a futurs models multimodals M/EEG aplicats a la descodificació de llenguatge natural.

Palabras clave: Decodificación neuronal; EEG; MEG; aprendizaje por transferencia; lectura natural; clasificación de palabras; modelos de contexto largo; brain-to-text

Abstract

Decoding words from non-invasive brain signals presents significant challenges due to the low level of useful signal, inter-subject variability, and differences between modalities such as MEG and EEG. In this work, the MEG-XL model—originally designed for learning long-range context representations in MEG—is adapted to an EEG setting during natural reading. The adaptation focuses on building a reproducible pipeline to evaluate whether representations learned in MEG can be transferred to EEG in word classification tasks. To this end, the MEG-XL architecture is integrated with a new adapter for various EEG datasets, which transforms EEG recordings and reading annotations into word-aligned segments. The pipeline incorporates resampling, normalization, word-based temporal window extraction, sensor masking, and explicit encoding of the EEG sensor type. From these segments, the model obtains contextualized neural representations using a Transformer with cross-attention and compares them with linguistic embeddings generated by T5 via a contrastive loss. The main objective is to analyze the technical and experimental feasibility of transferring long-context models trained on MEG data to EEG data in order to begin investigating an end-to-end brain-to-text solution that incorporates EEG. This approach allows us to study the practical barriers to cross-modal transfer, identify critical points in preprocessing, and lay the groundwork for future multimodal M/EEG models applied to natural language decoding.

Key words: Neural decoding; EEG; MEG; transfer learning; natural reading; word classification; long-context models; brain-to-text

Índice general

Índice general	V
Índice de figuras	VII
Índice de tablas	VII
1 Introducción	1
1.1 Motivación	1
1.2 Objetivos	1
1.3 Estructura de la memoria	1
2 Marco teórico	3
2.1 Interfaces cerebro-computador	3
2.1.1 Decodificación cerebral del lenguaje	3
2.1.2 Métodos invasivos y no invasivos	5
2.2 Electroencefalografía y magnetoencefalografía	5
2.2.1 Electroencefalografía	6
2.2.2 Magnetoencefalografía	7
2.2.3 Comparación entre EEG y MEG	7
2.3 Procesamiento de señales cerebrales	8
2.3.1 Actividad oscilatoria y bandas de frecuencia	9
2.3.2 Preprocesamiento de EEG y MEG	9
2.3.3 Representación temporal y espacial de las señales	11
2.4 Aprendizaje profundo para señales cerebrales	11
2.4.1 Redes neuronales y Transformers	11
2.4.2 Aprendizaje autosupervisado y transferencia de aprendizaje	11
2.4.3 Tokenización de señales neuronales	11
2.5 Decodificación contextual de palabras	11
2.5.1 Representaciones lingüísticas	11
2.5.2 Aprendizaje contrastivo	11
2.5.3 Evaluación de la clasificación de palabras	11
3 Estado del arte	13
3.1 Decodificación no invasiva del lenguaje	13
3.1.1 Decodificación mediante EEG	13
3.1.2 Decodificación mediante MEG	13
3.2 Datasets de lenguaje con EEG y MEG	13
3.2.1 Datasets de escucha	13
3.2.2 Datasets de lectura	13
3.3 Modelos preentrenados de señales cerebrales	13
3.3.1 Modelos para EEG	13
3.3.2 MEG-XL	13
3.4 Limitaciones de los trabajos existentes	13
4 Propuesta: adaptación de MEG-XL a EEG	15
4.1 Descripción general de la propuesta	16
4.2 Preparación de los datasets	16

4.2.1	Datasets de lectura	16
4.2.2	Datasets de escucha	16
4.2.3	Representación unificada de los datos	16
4.3	Preprocesamiento del EEG	16
4.3.1	Filtrado y remuestreo	16
4.3.2	Normalización y segmentación	16
4.3.3	Alineamiento con las palabras	16
4.4	Adaptación de la arquitectura MEG-XL	16
4.4.1	Adaptación de los canales EEG	16
4.4.2	Tokenización de la señal	16
4.4.3	Modelado temporal y espacial	16
4.5	Entrenamiento del modelo	16
4.5.1	Preentrenamiento autosupervisado	16
4.5.2	Clasificación contextual de palabras	16
4.5.3	Inicialización desde cero y desde MEG-XL	16
4.6	Implementación del sistema	16
4.6.1	Organización del repositorio	16
4.6.2	Ejecución y monitorización de experimentos	16
5	Evaluación experimental	17
5.1	Configuración de los experimentos	17
5.1.1	Particiones de los datos	17
5.1.2	Hiperparámetros y métricas	17
5.2	Influencia de la frecuencia de muestreo	17
5.3	Influencia de las bandas de frecuencia	17
5.4	Entrenamiento desde cero y transferencia desde MEG-XL	17
5.5	Comparación de tokenizadores	17
5.6	Comparación de tareas	17
5.6.1	Lectura	17
5.6.2	Escucha	17
5.6.3	Lectura y escucha combinadas	17
5.7	Discusión de los resultados	17
5.7.1	Principales conclusiones experimentales	17
5.7.2	Limitaciones	17
6	Conclusiones y trabajo futuro	19
6.1	Conclusiones	19
6.2	Cumplimiento de los objetivos	19
6.3	Líneas de trabajo futuro	19
Bibliografía		21
Apéndices		
A	Configuració del sistema	23
A.1	Fase d’inicialització	23
A.2	Identificació de dispositius	23
B	??? ?????????????? ????	25

Índice de figuras

Índice de tablas

2.1	Comparación general entre EEG y MEG.	8
2.2	Principales bandas de frecuencia utilizadas en el análisis de señales EEG y MEG. Los límites y las asociaciones funcionales son aproximados.	9

CAPÍTULO 1

Introducción

???? ????????????? ????????????? ????????????? ????????????? ?????????????

1.1 Motivación

???? ????????????? ????????????? ????????????? ????????????? ?????????????

1.2 Objetivos

???? ????????????? ????????????? ????????????? ????????????? ?????????????

1.3 Estructura de la memoria

???? ????????????? ????????????? ????????????? ????????????? ?????????????

CAPÍTULO 2

Marco teórico

2.1 Interfaces cerebro-computador

Las interfaces cerebro-computador (BCIs) son sistemas que establecen un canal de comunicación entre la actividad cerebral de una persona y un dispositivo externo [13]. Una BCI funciona de forma parecido a un ratón o una pantalla táctil, solo que intenta interpretar directamente determinados patrones de actividad neuronal y transformarlos en una salida útil. Esta salida puede ser desde mover un cursor o seleccionar una letra hasta controlar una prótesis o generar una secuencia de texto.

Durante los últimos años el interés por este tipo de sistemas ha aumentado considerablemente. Además del maravilloso trabajo que se está desarrollando en universidades y centros clínicos, la aparición de iniciativas privadas de gran visibilidad, como Neura-link, ha contribuido a acercar las BCIs al debate público [10]. Sin embargo, más allá de las expectativas generadas alrededor de estas tecnologías, su desarrollo sigue planteando dificultades importantes relacionadas con la adquisición de señales, la seguridad de los participantes, la cantidad de datos disponibles y la capacidad de los modelos para generalizar entre personas y sesiones.

De forma más o menos general, una BCI se puede dividir en varias etapas. En primer lugar, la actividad cerebral se registra mediante una modalidad de adquisición, como la electroencefalografía, magnetoencefalografía o electrocorticografía (las definiremos más adelante). Después, la señal obtenida se preprocesa para reducir ruido, artefactos y diferencias de escala. Sobre estos datos se extrae una representación que conserve la información relevante para la tarea. Finalmente, un modelo de decodificación transforma dicha representación en una predicción y, en los sistemas en línea, esta predicción se utiliza para actuar sobre un dispositivo o proporcionar *feedback* al usuario.

No todas las BCIs persiguen el mismo objetivo, algunas se basan en reconocer actividad generada voluntariamente por el usuario, como la imaginación motora o el habla imaginada. También existen sistemas pasivos que no buscan ejecutar una orden, sino estimar estados como la carga cognitiva, la atención o la fatiga. Dentro de esta variedad de aplicaciones, la decodificación cerebral del lenguaje es una de las líneas de investigación más ambiciosas, ya que pretende recuperar información lingüística directamente a partir de la actividad neuronal.

2.1.1. Decodificación cerebral del lenguaje

Se llama decodificación cerebral del lenguaje a la tarea de traducir información relacionada con el habla o la lectura a partir de señales cerebrales. Dependiendo del expe-

rimento, esta búsqueda de información puede centrarse en fonemas, sílabas, palabras, frases completas o propiedades semánticas de los datos que proporciona el participante. Cuando el objetivo final es reconstruir texto de forma continua, se suele emplear el término *brain-to-text*. No obstante, antes de alcanzar una transcripción completa, gran parte de la investigación se centra en tareas intermedias más controladas, como la detección de presencia de habla, la clasificación de fonemas o la identificación de palabras dentro de un vocabulario limitado [11, 7].

Hay diferentes situaciones o tareas en las que el lenguaje puede estar presente. En el habla producida o *overt speech*, la persona pronuncia en el experimento una palabra o una frase. Esta condición permite comprobar fácilmente el contenido generado, pero introduce las señales neurológicas relacionadas con el movimiento muscular de la boca, la lengua y la mandíbula. En el habla imaginada, llamada *covert speech*, *inner speech* o habla interna, lo que hace la persona es imaginar que pronuncia el contenido sin mover voluntariamente ningún músculo ni generar sonido. Esta segunda tarea resulta especialmente interesante para personas que no pueden hablar, que son las personas objetivo de este tipo de experimentos y sistemas, aunque también es más difícil de registrar y verificar [12, 1].

Una tercera posibilidad y en la que se desarrolla este trabajo es estudiar la percepción del habla. En este tipo de experimentos, el participante escucha palabras, frases o narraciones mientras se registra su actividad cerebral. Al existir un estímulo acústico conocido, es posible alinear con precisión los eventos lingüísticos con la señal neuronal. Esta característica ha permitido crear conjuntos de datos de gran tamaño basados en audiolibros y habla continua, como LibriBrain, en el que un participante escucha más de 50h de narraciones en inglés mientras se registra su actividad cerebral usando MEG [11]. Aunque escuchar habla no equivalga a producirla o imaginarla, constituye un escenario más adecuado que los anteriores para estudiar representaciones lingüísticas y desarrollar modelos de decodificación no invasiva a gran escala.

Por último, dentro de la percepción del habla encontramos también la opción de utilizar la lectura en lugar de la escucha. En este caso, la actividad cerebral que registra mientras el participante procesa palabras presentadas de forma aislada o dentro de frases. La lectura natural introduce una dificultad adicional: cada persona fija la mirada sobre las palabras durante intervalos diferentes y puede omitir o volver a leer fragmentos del texto. Por este motivo, algunos conjuntos de datos combinan EEG y seguimiento ocular. El *eye-tracking* permite localizar el inicio y la duración de cada fijación y, a partir de esta información, extraer segmentos de EEG asociados a palabras concretas. ZuCo es uno de los ejemplos más conocidos de este tipo de adquisición, ya que proporciona EEG de alta densidad y seguimiento ocular simultáneo durante la lectura natural de frases [6]. Otros datasets, en cambio, presentan palabras de forma aislada y controlan la duración de la presentación, lo que permite alinear la señal con mayor precisión [12, 1].

La señal relacionada con una palabra tiene más profundidad que simplemente el instante exacto en el que esta aparece. El procesamiento lingüístico tiene dependencias a diferentes escalas temporales. Los fonemas se agrupan en sílabas, las sílabas en palabras y las palabras adquieren diferentes significados dentro de frases y discursos. Además, la respuesta cerebral a una palabra puede depender de las palabras anteriores, de las expectativas del lector u oyente y del estado general del participante. Por ello, los enfoques recientes no solo analizan ventanas aisladas, sino secuencias de segmentos neuronales consecutivos. Esta incorporación de contexto permite al modelo utilizar relaciones entre palabras y patrones cerebrales que no son visibles cuando cada segmento se procesa de manera independiente [3, 8].

2.1.2. Métodos invasivos y no invasivos

Las técnicas utilizadas para registrar actividad cerebral se pueden dividir, de forma muy general, en métodos invasivos y no invasivos. Los métodos invasivos requieren una intervención quirúrgica para situar los sensores o sobre la superficie del cerebro o dentro del tejido cerebral. Entre ellos se encuentran la electrocorticografía (ECoG) y los conjuntos de microelectrodos intracorticales.

La principal ventaja de los métodos invasivos es la calidad de la señal. Al encontrarse tan cerca de donde se genera la actividad neuronal, los electrodos registran señales con mayor amplitud, mejor resolución espacial y menos atenuación que los sensores externos. Esta proximidad ha permitido obtener resultados muy destacados en decodificación tanto motora como del habla. En particular, algunos sistemas invasivos han conseguido reconstruir texto o sintetizar voz en personas con parálisis a partir de actividad cortical relacionada con los intentos del habla [7]. Sin embargo, estas prestaciones se obtienen a cambio de riesgos quirúrgicos, posibles infecciones, degradación de los electrodos y una cobertura limitada a las regiones implantadas. Por estos motivos su utilización suele restringirse a casos clínicos muy concretos y entornos de investigación controlados.

Los métodos no invasivos, en cambio, registran la actividad cerebral sin necesidad de cirugía. Dentro de este grupo encontramos sobre todo EEG, MEG y resonancia magnética (fMRI). Estas técnicas reducen considerablemente los riesgos para el participante y permiten realizar estudios replicables con mayor facilidad. Su principal limitación es la calidad de la señal, ya que debe atravesar diferentes tejidos o medirse a cierta distancia de su origen, lo que disminuye su resolución y añade mucho ruido.

Dentro de estos métodos, EEG y MEG destacan por su elevada resolución temporal. Ambas modalidades permiten seguir cambios cerebrales del orden de milisegundos, esta propiedad es muy importante para estudiar procesos tan rápidos como es la percepción de fonemas o palabras. La resonancia magnética funciona y ofrece una mejor resolución espacial, pero su respuesta es mucho más lenta y dificulta la separación temporal de palabras consecutivas. EEG y MEG constituyen, por tanto, un compromiso especialmente interesante entre seguridad y capacidad para representar la dinámica temporal del lenguaje.

Hay que tener en cuenta estos factores a la hora de entrenar diferentes modelos. Los sistemas invasivos disponen de señales más localizadas y, según el estudio, de muchas horas registradas para un mismo paciente. En cambio, los modelos no invasivos deben aprender a trabajar con señales más débiles, sensores distribuidos por toda la cabeza y una variabilidad elevada.

2.2 Electroencefalografía y magnetoencefalografía

Las corrientes postsinápticas, provenientes de poblaciones de neuronas, producen tanto potenciales eléctricos (EEG) como campos magnéticos (MEG). EEG registra las diferencias de potencial que llegan al cuero cabelludo, mientras que MEG mide los campos magnéticos producidos alrededor de la cabeza. Pese a que ambas modalidades ofrecen una resolución temporal elevada, sus propiedades físicas, su distribución espacial y sus sistemas de adquisición son diferentes.

Esta diferencia es lo suficientemente importante como para dedicarle un par de subsecciones en nuestro trabajo, sobre todo al tratar de realizar una transferencia de un tipo de método al otro. Un modelo no recibe directamente la actividad de las fuentes cerebrales, sino una mezcla de dichas fuentes observada a través de una disposición concreta

de sensores. Por tanto, cambiar de MEG a EEG no consiste únicamente en modificar el número de canales. También cambian la amplitud, la geometría, el tipo de ruido, la referencia y la relación entre cada sensor y las fuentes neuronales.

2.2.1. Electroencefalografía

La EEG registra diferencias de potencial eléctrico utilizando electrodos colocados sobre el cuero cabelludo. Estas diferencias se producen por la actividad sincronizada de grandes poblaciones de neuronas corticales. La amplitud registrada suele ser muy pequeña, en el orden de los microvoltios, por lo que el sistema de adquisición necesita amplificar señales muy pequeñas y mantener un buen contacto entre los electrodos y la piel.

La colocación de estos electrodos suele seguir sistemas estandarizados, como el sistema internacional 10–20 y sus extensiones 10–10 o 10–5. Estos sistemas asignan diferentes nombres a las posiciones en función de la región aproximada de la cabeza: frontal, central, temporal, parietal y occipital. En montajes de alta densidad se pueden utilizar 64, 128 o incluso más canales. Un mayor número de electrodos proporciona una más detallada observación espacial, aunque también incrementa el tiempo de preparación, la posibilidad de canales defectuosos y el coste computacional.

También hay que tener en cuenta que EEG es una medida relativa. Cada canal de EEG representa la diferencia entre un electrodo y una referencia o una combinación de ellas. La elección de esta referencia afecta a la forma de la señal y debe tenerse en cuenta al comparar conjuntos de datos. Dentro de las opciones habituales encontramos la referencia a un electrodo concreto, la referencia promedio de todos los canales o configuraciones bipolares. En conjuntos de datos que están recogidos con diferentes sistemas, una estrategia de referencia homogénea puede reducir parte de las diferencias, pero no elimina por completo la variabilidad entre los montajes.

Como hemos comentado antes, una de las principales ventajas de EEG es su resolución temporal. Es capaz de registrar frecuencias de cientos o miles de muestras por segundo, lo que permite estudiar respuestas rápidas asociadas a estímulos visuales, auditivos o lingüísticos. También es una tecnología –relativamente– económica, portátil y compatible con experimentos naturales. Estas características explican su uso frecuente en BCI y en estudios de lectura, donde puede combinarse con seguimiento ocular para obtener segmentos asociados a cada fijación [6]

Su principal limitación es la resolución espacial. Los potenciales eléctricos se propagan a través del cerebro, el líquido cefalorraquídeo, el cráneo y el cuero cabelludo. La conductividad de estos tejidos produce un fenómeno de difusión conocido como conducción de volumen, por el cual una misma fuente puede afectar a numerosos electrodos. Como consecuencia, la actividad que se observa en un canal no puede asociarse directamente a una única región cerebral.

Por otro lado, las señales EEG también pueden contaminarse con actividad que no procede directamente del cerebro (estas contaminaciones se llaman artefactos). Los parpadeos y movimientos oculares generan señales de gran amplitud en los electrodos frontales. La tensión muscular, el movimiento de la mandíbula, el latido cardíaco, el desplazamiento de los cables y el contacto deficiente de los electrodos pueden ocultar la actividad neuronal. En tareas de habla producida, los artefactos musculares son especialmente relevantes. En lectura natural, los movimientos oculares forman parte de la propia tarea, de modo que su tratamiento debe realizarse con cuidado para no eliminar información relacionada indirectamente con el procesamiento lingüístico.

2.2.2. Magnetoencefalografía

Por su contraparte, MEG registra los campos magnéticos generados por la actividad neuronal. Estos campos detectados son extremadamente débiles, normalmente del orden de femtoteslas, por lo que se necesitan sensores muy sensibles y salas completamente protegidas a interferencias magnéticas externas. Los sistemas tradicionales utilizan dispositivos superconductores de interferencia cuántica, conocidos como SQUID. Asimismo se están desarrollando sistemas basados en magnetómetros de bombeo óptico, que permiten situar los sensores más cerca de la cabeza y ofrecen nuevas posibilidades para dispositivos más flexibles.

Los sistemas MEG suelen tener 2 tipos de sensores: magnetómetros y gradiómetros. Los magnetómetros miden directamente la intensidad del campo magnético, mientras que los gradiómetros registran diferencias espaciales del campo y ayudan a reducir interferencias externas. Un equipo MEG de cuerpo completo puede contener más de trescientos canales distribuidos alrededor de la cabeza. Por ejemplo, LibriBrain fue registrado con un sistema MEGIN Triux Neo de 306 canales [11].

A diferencia de los potenciales eléctricos, los campos magnéticos atraviesan el cráneo y el cuero cabelludo con menor distorsión. Esto proporciona a MEG una resolución espacial superior a la de EEG en muchas condiciones, manteniendo una resolución temporal del orden de milisegundos. Estas propiedades han convertido MEG en una modalidad especialmente utilizada para estudiar percepción auditiva, lenguaje y habla continua [4].

MEG también presenta limitaciones importantes. El equipamiento tiene un coste mucho más elevado que el de EEG, requiere instalaciones específicas y no es fácilmente transportable. El participante debe permanecer relativamente quieto, ya que el movimiento de la cabeza modifica la relación entre las fuentes cerebrales y los sensores. Además, los datos ocupan mucho espacio y su procesamiento suele incluir pasos específicos, como corrección del movimiento de la cabeza, detección de canales defectuosos y separación de señales de origen externo mediante técnicas como *Signal Space Separation* o filtrado de Maxwell.

Otra propiedad relevante es que los sistemas MEG no comparten necesariamente la misma disposición de sensores. Distintos fabricantes utilizan cantidades, tipos y geometrías diferentes. Incluso dentro del mismo sistema, la posición de la cabeza puede cambiar entre sesiones. Para combinar datos de varios conjuntos, los modelos deben representar de algún modo la localización, la orientación y el tipo de sensor, o transformar previamente las señales a un espacio común.

MEG ha permitido desarrollar algunos de los conjuntos de datos más relevantes para la decodificación no invasiva del habla. La mayor calidad de la señal, unida a adquisiciones prolongadas, ha facilitado tareas de detección de habla, clasificación de fonemas y clasificación contextual de palabras. Estos resultados hacen que los modelos preentrenados con MEG constituyan una base interesante para estudiar su transferencia a EEG, aunque las diferencias entre modalidades impiden asumir que dicha transferencia será directa.

2.2.3. Comparación entre EEG y MEG

EEG y MEG comparten su carácter no invasivo y su elevada resolución temporal, pero presentan diferencias importantes en la forma en que observan la actividad cerebral. La Tabla 2.1 resume las propiedades más relevantes para este trabajo.

Desde el punto de vista del aprendizaje automático, ambas modalidades suelen representarse inicialmente como una matriz de canales por tiempo. Sin embargo, esta similitud

Tabla 2.1: Comparación general entre EEG y MEG.

Propiedad	EEG	MEG
Magnitud registrada	Diferencias de potencial eléctrico en el cuero cabelludo.	Campos magnéticos producidos por corrientes neuronales.
Resolución temporal	Elevada, normalmente del orden de milisegundos.	Elevada, normalmente del orden de milisegundos.
Resolución espacial	Limitada por la conducción de volumen y la referencia.	Generalmente superior, con menor distorsión causada por el cráneo.
Sensibilidad a fuentes	Sensible a fuentes radiales y tangenciales.	Principalmente sensible a fuentes tangenciales en sistemas convencionales.
Artefactos frecuentes	Parpadeos, movimientos oculares, actividad muscular, referencia y contacto de electrodos.	Movimiento de cabeza, interferencias magnéticas, actividad cardíaca y muscular.
Portabilidad y coste	Relativamente económico y portable.	Coste elevado y necesidad de instalaciones especializadas.
Preparación	Colocación de electrodos y control de impedancias.	Digitalización de la cabeza, localización de sensores y control de movimiento.
Variabilidad entre conjuntos	Número y posición de electrodos, referencia, amplificador y frecuencia de muestreo.	Geometría, tipo de sensor, posición de la cabeza y sistema de adquisición.

de formato puede resultar engañosa. Los canales de EEG y MEG no son intercambiables, y una misma fuente cortical se proyecta de forma diferente en cada modalidad. Además, EEG suele tener menos canales y una relación señal-ruido inferior, mientras que MEG proporciona una estructura espacial más rica.

Estas diferencias generan un problema de cambio de dominio. Un modelo entrenado con MEG puede haber aprendido patrones que dependen de la geometría de sus sensores, de la amplitud de la señal o del tipo de ruido presente en el escáner. Al aplicarlo sobre EEG, estas relaciones dejan de cumplirse. Por ello, la transferencia requiere adaptar la entrada, normalizar la señal, representar la posición de los electrodos y, en muchos casos, reajustar parte o la totalidad del modelo.

Aun así, EEG y MEG comparten información temporal y neurofisiológica. Ambas modalidades reflejan la actividad coordinada de poblaciones neuronales y contienen respuestas relacionadas con el procesamiento de palabras. Esta base común justifica estudiar si las representaciones aprendidas mediante preentrenamiento MEG pueden aportar información útil para EEG, especialmente en escenarios con pocos datos etiquetados. El objetivo no es asumir que ambas señales son iguales, sino determinar qué partes del conocimiento aprendido son transferibles y qué componentes deben adaptarse.

2.3 Procesamiento de señales cerebrales

Las señales EEG y MEG se registran como series temporales multicanal. Si se utilizan C sensores y se obtienen T muestras, una grabación se puede representar como una matriz

$$\mathbf{X} \in \mathbb{R}^{C \times T}.$$

Esta representación contiene simultáneamente información temporal y espacial, pero también ruido, artefactos y diferencias instrumentales. Antes de entrenar un modelo es ne-

cesario decidir qué parte de la señal se conserva, cómo se normaliza y cómo se divide en muestras.

El procesamiento no debe entenderse únicamente como una limpieza previa. Cada decisión modifica la información que el modelo puede utilizar. Un filtro demasiado restrictivo puede eliminar componentes relacionadas con la tarea, mientras que una limpieza insuficiente puede hacer que el clasificador aprenda artefactos. Del mismo modo, una segmentación incorrecta puede asociar una etiqueta lingüística a una ventana que no contiene la respuesta cerebral correspondiente.

2.3.1. Actividad oscilatoria y bandas de frecuencia

La actividad registrada mediante EEG y MEG suele estudiarse en el dominio de la frecuencia. La frecuencia representa el número de ciclos de una oscilación que se producen en un segundo y se expresa en hercios. De manera aproximada, estas oscilaciones suelen agruparse en las bandas delta, theta, alfa, beta y gamma. Esta división permite resumir cambios en la actividad cerebral y estudiar su relación con diferentes estados fisiológicos y procesos cognitivos.

Tabla 2.2: Principales bandas de frecuencia utilizadas en el análisis de señales EEG y MEG. Los límites y las asociaciones funcionales son aproximados.

Banda	Intervalo aproximado	Asociaciones habituales
Delta	0.5–4 Hz	Sueño profundo y actividad cerebral lenta.
Theta	4–8 Hz	Procesos de aprendizaje, memoria y control cognitivo.
Alfa	8–13 Hz	Estados de reposo, regulación de la atención e inhibición de información no relevante.
Beta	13–30 Hz	Procesamiento cognitivo y sensoriomotor activo.
Gamma	> 30 Hz	Integración de información y diferentes procesos perceptivos y cognitivos.

Estas asociaciones deben entenderse de manera aproximada, ya que las bandas no representan componentes completamente independientes ni se corresponden de forma exclusiva con una única función cerebral. Su interpretación depende de la región registrada, de la tarea realizada y del momento analizado [2, 9, 5].

En los estudios de habla imaginada se han utilizado combinaciones muy diferentes de frecuencias, desde bandas bajas hasta intervalos gamma, sin que exista una banda universalmente óptima para todos los participantes, tareas y conjuntos de datos [12, 1]. Por este motivo, tanto los límites del filtrado como la frecuencia de muestreo deben considerarse decisiones relevantes cuando se adapta un modelo a nuevos conjuntos de EEG. Una frecuencia de muestreo reducida disminuye el coste computacional, pero también limita las componentes espectrales que pueden conservarse.

2.3.2. Preprocesamiento de EEG y MEG

El primer paso suele ser comprobar la calidad de la grabación. Durante esta revisión se identifican canales planos, saturados o excesivamente ruidosos. Estos canales pueden eliminarse, interpolarse a partir de sensores vecinos o marcarse para que el modelo no los utilice. También es importante verificar la sincronización entre la señal cerebral y los eventos del experimento, especialmente cuando las ventanas se alinean con el inicio de una palabra, un estímulo auditivo o una fijación ocular.

En EEG, el preprocesamiento puede incluir una nueva referencia de los canales. La referencia promedio es una opción común en sistemas de alta densidad, aunque su idoneidad depende de la cobertura de electrodos. También se revisan las impedancias y se eliminan canales periféricos muy afectados por actividad muscular. En MEG no existe una referencia eléctrica equivalente, pero son habituales la corrección del movimiento de la cabeza y los métodos que separan las fuentes internas y externas al casco. En LibriBrain, por ejemplo, se aplica filtrado de Maxwell, eliminación de canales defectuosos, filtros para la red eléctrica y reducción de la frecuencia de muestreo [11].

El filtrado temporal busca conservar un intervalo de frecuencias útil y reducir componentes no deseadas. Un filtro paso alto elimina las variaciones muy lentas y la deriva de la línea base. Un filtro paso bajo reduce el ruido de alta frecuencia y prepara la señal para un posible remuestreo. También se utilizan filtros *notch* en la frecuencia de la red eléctrica, que en Europa es de 50 Hz, y en algunos de sus armónicos. La elección de los límites debe estar relacionada con la tarea y con la nueva frecuencia de muestreo. Antes de reducir la frecuencia es necesario aplicar un filtrado antialiasing que elimine componentes superiores a la frecuencia de Nyquist.

El remuestreo reduce la cantidad de puntos temporales y, por tanto, el coste de almacenamiento y entrenamiento. Esta reducción es especialmente importante en modelos de contexto largo, donde el número de elementos de entrada crece con la duración, el número de canales y la frecuencia de muestreo. MEG-XL, por ejemplo, utiliza señales remuestreadas a 50 Hz para poder procesar ventanas de dos minutos y medio [8]. Sin embargo, una frecuencia menor también limita las componentes espectrales disponibles. En EEG no existe una frecuencia óptima universal para la decodificación de palabras, por lo que su selección debe evaluarse experimentalmente.

La eliminación de artefactos es uno de los pasos más delicados. En EEG se emplea con frecuencia el análisis de componentes independientes, conocido como ICA, para separar fuentes con patrones espaciales y temporales distintos. Posteriormente, se identifican los componentes asociados a parpadeos, movimientos oculares, actividad cardíaca o tensión muscular. Esta identificación puede realizarse manualmente o mediante métodos automáticos como MARA. ZuCo utiliza una estrategia automática basada en ICA para eliminar componentes oculares y musculares antes de sincronizar EEG y seguimiento ocular [6].

A pesar de su utilidad, la eliminación de artefactos no está exenta de riesgos. En una tarea de lectura, la actividad ocular está relacionada con el momento en que se procesa cada palabra. Eliminar toda señal correlacionada con los ojos podría suprimir parte de la estructura temporal necesaria para la alineación. De manera similar, en habla producida, un modelo puede alcanzar una precisión elevada utilizando actividad muscular en lugar de actividad cerebral. Por ello, el tratamiento de artefactos debe ajustarse al objetivo del experimento y acompañarse de controles que permitan detectar atajos no deseados.

Después del filtrado, las señales suelen normalizarse. Una normalización global puede verse dominada por diferencias entre sesiones o por valores extremos. Por este motivo, se utilizan estrategias por canal, por grabación o por segmento. Entre ellas se encuentran la estandarización mediante media y desviación típica, la normalización robusta mediante mediana y rango intercuartílico y el recorte de valores extremos. MEG-XL divide las muestras largas en subsegmentos de tres segundos, corrige la línea base, normaliza mediante estadísticos robustos y limita los valores a un intervalo fijo [8]. Este tipo de transformación reduce las diferencias de escala sin depender excesivamente de valores anómalos.

La última etapa es la segmentación. En clasificación de palabras, cada ejemplo se obtiene normalmente a partir de una ventana alineada con un evento lingüístico. En escu-

cha, este evento puede ser el inicio de la palabra en el audio. En lectura, puede ser el momento en que comienza una fijación sobre la palabra. La ventana puede incluir señal anterior al evento para corregir la línea base y señal posterior para capturar respuestas tardías. Cuando se procesan secuencias completas, varias ventanas consecutivas se agrupan manteniendo su orden original.

La división entre entrenamiento, validación y prueba también forma parte del procesamiento. No es suficiente con separar ventanas aleatoriamente si segmentos cercanos pertenecen a la misma grabación o al mismo estímulo. Esto puede producir fugas de información, ya que el modelo reconoce propiedades específicas de la sesión o del contenido. Siempre que sea posible, deben mantenerse sesiones, sujetos o estímulos completos dentro de una única partición. En conjuntos donde varios participantes reciben el mismo estímulo, todas las repeticiones de dicho estímulo deben asignarse a la misma partición.

2.3.3. Representación temporal y espacial de las señales

2.4 Aprendizaje profundo para señales cerebrales

2.4.1. Redes neuronales y Transformers

2.4.2. Aprendizaje autosupervisado y transferencia de aprendizaje

2.4.3. Tokenización de señales neuronales

2.5 Decodificación contextual de palabras

2.5.1. Representaciones lingüísticas

2.5.2. Aprendizaje contrastivo

2.5.3. Evaluación de la clasificación de palabras

CAPÍTULO 3

Estado del arte

3.1 Decodificación no invasiva del lenguaje

3.1.1. Decodificación mediante EEG

3.1.2. Decodificación mediante MEG

3.2 Datasets de lenguaje con EEG y MEG

3.2.1. Datasets de escucha

3.2.2. Datasets de lectura

3.3 Modelos preentrenados de señales cerebrales

3.3.1. Modelos para EEG

3.3.2. MEG-XL

3.4 Limitaciones de los trabajos existentes

CAPÍTULO 4

Propuesta: adaptación de MEG-XL a EEG

4.1 Descripción general de la propuesta

4.2 Preparación de los datasets

4.2.1. Datasets de lectura

4.2.2. Datasets de escucha

4.2.3. Representación unificada de los datos

4.3 Preprocesamiento del EEG

4.3.1. Filtrado y remuestreo

4.3.2. Normalización y segmentación

4.3.3. Alineamiento con las palabras

4.4 Adaptación de la arquitectura MEG-XL

4.4.1. Adaptación de los canales EEG

4.4.2. Tokenización de la señal

4.4.3. Modelado temporal y espacial

4.5 Entrenamiento del modelo

4.5.1. Preentrenamiento autosupervisado

4.5.2. Clasificación contextual de palabras

4.5.3. Inicialización desde cero y desde MEG-XL

4.6 Implementación del sistema

4.6.1. Organización del repositorio

4.6.2. Estructura de implementación del sistema

CAPÍTULO 5

Evaluación experimental

5.1 Configuración de los experimentos

5.1.1. Particiones de los datos

5.1.2. Hiperparámetros y métricas

5.2 Influencia de la frecuencia de muestreo

5.3 Influencia de las bandas de frecuencia

5.4 Entrenamiento desde cero y transferencia desde MEG-XL

5.5 Comparación de tokenizadores

5.6 Comparación de tareas

5.6.1. Lectura

5.6.2. Escucha

5.6.3. Lectura y escucha combinadas

5.7 Discusión de los resultados

5.7.1. Principales conclusiones experimentales

5.7.2. Limitaciones

CAPÍTULO 6

Conclusiones y trabajo futuro

6.1 Conclusiones

6.2 Cumplimiento de los objetivos

6.3 Líneas de trabajo futuro

Bibliografía

- [1] Salwa Alzahrani, Haneen Banjar, and Rsha Mirza. Systematic review of eeg-based imagined speech classification methods. *Sensors*, 24(24):8168, 2024.
- [2] György Buzsáki and Andreas Draguhn. Neuronal oscillations in cortical networks. *Science*, 304(5679):1926–1929, 2004.
- [3] Stéphane d’Ascoli, Corentin Bel, Jérémy Rapin, Hubert Banville, Yohann Benche-trit, Christophe Pallier, and Jean-Rémi King. Decoding individual words from non-invasive brain recordings across 723 participants. *arXiv preprint arXiv:2412.17829*, 2024.
- [4] Debadatta Dash, Paul Ferrari, and Jun Wang. Decoding imagined and spoken phrases from non-invasive neural (meg) signals. *Frontiers in Neuroscience*, 14:290, 2020.
- [5] Andreas K. Engel and Pascal Fries. Beta-band oscillations—signalling the status quo? *Current Opinion in Neurobiology*, 20(2):156–165, 2010.
- [6] Nora Hollenstein, Marius Troendle, Ce Zhang, and Nicolas Langer. Zuco 2.0: A dataset of physiological recordings during natural reading and annotation. In *Proceedings of the 12th Language Resources and Evaluation Conference*, pages 138–146, 2020.
- [7] Dulhan Jayalath, Gilad Landau, and Oiwi Parker Jones. Unlocking non-invasive brain-to-text. *arXiv preprint arXiv:2505.13446*, 2025.
- [8] Dulhan Jayalath and Oiwi Parker Jones. Meg-xl: Data-efficient brain-to-text via long-context pre-training. *arXiv preprint arXiv:2602.02494*, 2026.
- [9] Wolfgang Klimesch. EEG alpha and theta oscillations reflect cognitive and memory performance: A review and analysis. *Brain Research Reviews*, 29(2–3):169–195, 1999.
- [10] Elon Musk and Neuralink. An integrated brain-machine interface platform with thousands of channels. *Journal of Medical Internet Research*, 21(10):e16194, 2019.
- [11] Miran Özdogan, Gilad Landau, Gereon Elvers, Dulhan Jayalath, Pratik Somaiya, Francesco Mantegna, Mark Woolrich, and Oiwi Parker Jones. Libribrain: Over 50 hours of within-subject meg to improve speech decoding methods at scale. *arXiv preprint arXiv:2506.02098*, 2025.
- [12] Jerrin Thomas Panachakel and Angarai Ganesan Ramakrishnan. Decoding covert speech from eeg—a comprehensive review. *Frontiers in Neuroscience*, 15:642251, 2021.
- [13] Jonathan R. Wolpaw, Niels Birbaumer, Dennis J. McFarland, Gert Pfurtscheller, and Theresa M. Vaughan. Brain-computer interfaces for communication and control. *Clinical Neurophysiology*, 113(6):767–791, 2002.

APÉNDICE A

Configuració del sistema

???? ????????????? ????????????? ????????????? ????????????? ?????????????

A.1 Fase d'inicialització

???? ????????????? ????????????? ????????????? ????????????? ?????????????

A.2 Identificació de dispositius

???? ????????????? ????????????? ????????????? ????????????? ?????????????

APÉNDICE B

??? ?????????????? ????

???? ?????????????? ?????????????? ?????????????? ?????????????? ??????????????